

Модели данных

А2. Нормализация реляционных данных



Московский государственный технический университет
имени Н.Э. Баумана

Факультет ИБМ

Июль 2024 года

Москва


Артемьев Валерий Иванович © 2024

Курс «Моделирование данных»

2. Нормализация реляционных данных

- Понятия реляционного подхода, ER-модели и баз данных
- Нормализация отношений
- Избыточность и аномалии изменения
- Начальные условия для нормализации
- 1-ая нормальная форма
- Что делать с перегруженными атрибутами?
- Что делать с наложенными атрибутами?
- 2-ая нормальная форма
- 3-ья нормальная форма
- Пример. Проверка соответствия ЛМД до 3NF
- Обновлённые диаграммы ЛМД и КМД примера

Соотношение понятий реляционного подхода, ER-модели и баз данных




Нормализация реляционных отношений



Нормализация реляционных отношений – метод моделирования и проектирования реляционных БД путём приведения структуры и состава данных в соответствие с определёнными правилами и требованиями, к эталонному виду.

- Зачем нужна нормализация отношений?
 - снижение избыточности данных
 - устранение аномалий ведения данных
 - повышение гибкости
 - увеличение производительности до определённого предела
 - повышение качества данных
- Нормальные формы – наборы *расширяемых правил* и требований нормализации отношений
 - сейчас существует 8 нормальных форм
 - на практике достаточно нормализация до 3NF
- Контроль ЛМД при проектировании «сверху – вниз»
- Создание ЛКМ / ФМД при проектировании «снизу – вверх»
 - часто приводит к разбиению таблицы без потерь на несколько таблиц с установлением связей



Избыточность данных и аномалии изменения данных



Избыточность данных возникает в базах данных, когда одни и те же значения определённой колонки повторяются в разных строках таблицы, что приводит к аномалиям изменения.

При изменении данных может возникнуть их *несогласованность*, *потеря качества данных*.

Различают *аномалии изменений*:

- *аномалии добавления* – надо добавить ещё и другие данные
- *аномалии обновления* – изменять нужно в нескольких местах
- *аномалии удаления* – удаление может затронуть другие данные

Первопричина – избыточность, следствия – аномалии изменений данных.

Начальные условия для нормализации отношений



Прежде всего, согласно реляционной теории данные должны быть, представлены в виде кортежей и атрибутов отношений, а реляционные базы данных – в виде строк и колонок таблицы.

При этом

- *Не упорядочены кортежи (строки таблицы)*
- *Фиксирован состав атрибутов (колонок таблицы)*
- *Не упорядочены атрибуты (колонки таблицы)*

Таблица	Колонки		
Строки			

Некоторые называют это нулевой нормальной формой.

Не упорядочены кортежи (строки таблицы)



В реляционной теории отношения состоят из неупорядоченных кортежей, поэтому в реляционных БД строки хранятся в произвольном порядке.

- Кортежи (строки) *не упорядочены* по значению к-л атрибута
- Но строки *можно сортировать* по атрибутам при выборке
- *Нельзя выбрать n-ую строку* из таблицы
- Но *можно выдать n строк* из результата запроса, в частности одну

Нельзя полагаться на физический порядок строк в реляционной БД.

Фиксирован состав атрибутов (колонок таблицы)



В реляционной теории фиксирован состав атрибутов отношения, поэтому в реляционной БД фиксирован состав колонок таблицы.

- В процессе работы с БД у таблиц фиксирован состав колонок
- Имена колонок – свойства сущности, а не значения свойств
- Изменения по времени разворачивайте по строкам
- Не разворачивайте изменения по колонкам
- Но состав колонок можно изменить при реорганизации БД
- Можно резервировать колонки с необязательными значениями
- Можно применить универсальные модели данных, напр., EVA



Реляционная модель не поддерживает переменный состав атрибутов.

Не упорядочены атрибуты (колонки таблицы)



В реляционной теории состав атрибутов отношения не упорядочен, поэтому в реляционной БД явный порядок колонок не поддерживается.

- Расположение колонок таблицы скрыто от пользователя
- Описание из словаря БД будет отсортировано по именам колонок
- Данные выбираются по именам колонок из таблицы
- Нельзя выбрать n -ую колонку из таблицы
- Но можно сослаться на n -ое поле в рамках запроса

Нельзя полагаться на порядок колонок в реляционной таблице.

1-ая нормальная форма

1NF



Отношение (таблица) находится в 1NF, когда оно соответствует начальным условиям для нормализации реляционных данных, и в нём:

- нет кортежей (строк) с дублирующим содержимым
- семантически однозначные атрибуты (колонки) с атомарными, однотипными значениями

и накладывается ряд дополнительных требований к атрибутам, которые влияют на фильтрацию и агрегирование значений:

- одинаковая детальность значений (первичные данные или итоги)
- одинаковые единицы измерения (км/час или миль/час)
- согласованные позиции справочников
- определённый формат значений (тыс. руб. или руб. коп.)

Всё внимание к соблюдению реляционных принципов.

Нет кортежей (строк) с дублирующим содержимым

1NF



Каждый кортеж (строка таблицы) должен содержать уникальное значение.

Табельный номер	Фамилия, имя, отчество сотрудника	Подразделение
1234	Иванов Илья Степанович	Отдел 75
1234	Илья Степанович Иванов	Отдел 75
1235	Иванов Пётр Семёнович	Отдел 76
1235	Иванов Пётр Семёнович	Отдел 76

Реальная дедубликация сложнее, относится к управлению качеством данных.

Семантически однозначные атрибуты с атомарными, однотипными значениями 1NF



Нарушение этих требований 1NF приводит:

- 1) **перегруженные атрибуты** – составные и многозначные атрибуты (например: несколько разнотипных значений или список)
- 2) **наложенные атрибуты** – семантически неоднозначные, возможно однотипные значения (например: наименование организации или ФИО)
 - Приемлемые при презентации/ визуализации данных (отчёты, панели мониторинга, слайды), но могут восприниматься как **дефекты качества данных** при сборе/ обработке/ анализе данных
 - Специальный признак трактовки значений нужен для наложенных атрибутов

Нарушение требований 1NF может провоцировать создание неудачных структур БД и снижение качества данных

Что делать с перегруженными атрибутами?

1NF



Перегруженные атрибуты фактически являются вложенными таблицами с неявной структурой, похожи на строку формата CSV (с разделителями):

2023-10-04; №1234; Б

+7(495)123-45-67; +7(499) 987-65-43

1. Если значения перегруженных атрибутов не подлежат контролю/ обработке/ анализу, скорее являются комментариями, то нужно оставить их, но оговорить синтаксис списка.
2. Если перегруженные атрибуты подлежат контролю/ обработке/ анализу, то нужно:
 - для составных атрибутов создать дополнительные атрибуты
 - для многозначных атрибутов разнести значения по разным записям или выделить в отдельную таблицу или создать дополнительные атрибуты

Идент.		Дата протокола	Номер протокола	Индекс решения
101		2023-10-04	№1234	Б
...		...	...	...

Идент.	Номер телефона
123	+7(495)123-45-67
123	+7(499) 987-65-43

Идент.		Номер служебного телефона	Номер домашнего телефона
123		+7(495)123-45-67	+7(499) 987-65-43

Пример наложенных атрибутов

1NF



Тип клиента	Полное наименование юридического лица / Фамилия, имя, отчество физического лица, индивидуального предпринимателя	ИНН (TIN) юридического лица / индивидуального предпринимателя // Код документа, удостоверяющего физическое лицо	ОГРН юридического лица / ОГРН ИП / Серия, номер документа, удостоверяющего физическое лицо
ЮЛ	Полное наименование юридического лица - резидента	ИНН юридического лица - резидента	ОГРН юридического лица - резидента согласно ЕГРЮЛ
ЮЛ	Полное наименование юридического лица - нерезидента	Идентиф. номер налогоплательщика - иностранной организации (или его аналог) или Регистрационный номер в стране регистрации	
ИП	Фамилия, имя, отчество индивидуального предпринимателя	ИНН индивидуального предпринимателя - резидента	ОГРН индивидуального предпринимателя - резидента согласно ЕГРИП
ФЛ	Фамилия, имя, отчество физического лица	Код документа, удостоверяющего физическое лицо -	Серия, номер документа, удостоверяющего физическое лицо

Недостатки:

- 1) резидентность субъекта явно не определена, нет указания страны регистрации
- 2) значение TIN или регистрационного номера нерезидента может совпасть с ИНН юрлица, физлица или ИП
- 3) неявный признак нерезидента юрлица – отсутствие значения атрибута «ОГРН...»

Что делать с наложенными атрибутами?

1NF




1. Если требуется наличие хотя бы одного идентификатора субъекта, то можно оставить **наложенный атрибут** со значением идентификатора и признаками (атрибутами), которые позволяют определить вид частного идентификатора, тип субъекта и его резидентность.

Страна регистрации субъекта	Тип субъекта	Вид частного идентификатора субъекта	Значение частного идентификатора
РФ	ЮЛ	ОГРН	1234567890123
РФ	ИП	ОГРНИП	983456789012345
РФ	ФЛ	ИНН	987654321012
США	ЮЛ	TIN	5467341289

При таком подходе остаётся возможность контролировать, обрабатывать / анализировать значения идентификаторов. Можно также сгенерировать уникальный идентификатор.

2. Если важны и другие или все атрибуты субъекта, то следует их разместить в отдельные таблицы с идентификатором субъекта. Важно типизировать такие представления в рамках всей предметной области.



2-ая нормальная форма

2NF
1NF



Таблица (отношение) находится в 2NF, когда

- *таблица находится в 1NF*
- *таблица имеет ключ – уникальный идентификатор*
- *все неключевые колонки (атрибуты) зависят от полного ключа (если он составной)*

Если таблица имеет простой первичный ключ (естественный или суррогатный), то она находится в 2NF.

Если таблица имеет составной первичный ключ, но не имеет неключевых атрибутов, то она находится в 2NF.

Если таблица имеет составной первичный ключ и неключевые атрибуты, зависящие от всех ключей, то она находится в 2NF.

В центре внимания 2NF находится первичный ключ таблицы.

3-ья нормальная форма

Таблица (отношение) находится в 3NF, когда

- *таблица находится в 2NF*
- *отсутствует транзитивная зависимость, когда неключевые атрибуты зависят от значений других неключевых атрибутов.*

Основной механизм – *декомпозиция таблиц.*

Способствует выделению справочников-классификаторов и реестров, в которых каждый класс или субъект (объект) содержится однократно, что сокращает избыточность данных и устраняет аномалии изменений.

Всё внимание в 3NF привлечено к неключевым атрибутам.

Денормализация реляционных отношений


2NF
1NF



Денормализация отношений – сознательное снижение нормализации до 2NF и даже до 1NF для обеспечения компромисса между объёмом БД и временем выполнения запросов.

- Нормализация отношений приводит к декомпозиции структуры данных на множество простых сущностей (таблиц). Это главное требование для транзакционных (учётно-операционных) систем для исключения аномалий изменений.
- Однако множество таблиц увеличивает время выполнения запросов из-за необходимости их связывания.
- При аналитической обработке данных нормализация имеет меньшее значение и чаще применяется денормализация.
- Примеры денормализации:
 - исключение простых справочников (пол, состояние и т.п.), встраивание в виде атрибута, при вводе – выбор из меню
 - перенос справочников разных уровней иерархии на один уровень, так, издатель ссылается на справочники городов и стран
 - плоский файл при приемлемом объёме данных.

Пример. ЛМД «Домашняя библиотека» (простая нотация)



Пример. Проверка соответствия ЛМД требованиям 1NF



У сущности СОЗДАТЕЛЬ имеется *составной семантически неоднозначный* атрибут создатель_ФИО где может нарушаться порядок составляющих элементов, а вместо имени, отчества могут содержаться инициалы.

Решения:

- 1) разделить создатель_ФИО на атрибуты создатель_фамилия, создатель_имя, создатель_отчество (необязательный) и добавить атрибут создатель_инициалы с необязательным значением, сцеплением можно обеспечить любой порядок элементов.
- 2) Если допустимо, то можно ограничиться атрибутами создатель_фамилия и создатель_инициалы (обязательное значение).

СОЗДАТЕЛЬ
создатель_ID
создатель_фамилия
создатель_имя
○ создатель_отчество
○ создатель_инициалы

СОЗДАТЕЛЬ
создатель_ID
создатель_фамилия
создатель_инициалы

Исправить таблицу описания ЛМД

Других несоответствий требованиям 1NF не было обнаружено.

Пример. Проверка соответствия ЛМД требованиям 2NF



- Сущности (таблицы) КНИГА, ТЕМА, ИЗДАНИЕ_ВИД, СОЗДАТЕЛЬ, СОЗДАТЕЛЬ_РОЛЬ, ИЗДАТЕЛЬСТВО, ГОРОД, СТРАНА, РАЗМЕЩЕНИЕ, ЧИТАТЕЛЬ имеют простые первичные ключи (суррогатные) и, значит, находятся в 2NF.
- Сущность УЧАСТИЕ имеет составной первичный ключ из ключевых атрибутов книга_ID, создатель_ID, роль_ID, но не имеет неключевых атрибутов, поэтому находится в 2NF.

Пример. Проверка соответствия ЛМД требованиям 3NF




В модели сущность ЧИТАТЕЛЬ первоначально имела неключевые атрибуты дата_выдачи, срок_возврата.

Они связаны между собой, но слабо связаны с читателем.

Реквизиты читателя повторяются с каждой взятой книгой – избыточность и аномалии изменений.

Следует декомпозировать сущность ЧИТАТЕЛЬ на две сущности ВЫДАЧА и ЧИТАТЕЛЬ на ER-диаграмме:



Согласно выбранным правилам именования изменены имена атрибутов дата_выдачи, срок_возврата на имена выдача_дата, возврат_срок. Соответственно нужно изменить таблицу описания КМД и ЛМД.


Других несоответствий 3NF не было обнаружено.

Пример. Обеспечение гибкости модели данных – нормализация 3NF+




Как в модели Домашняя библиотека отразить размещение книги?

Вар. 1




Наиболее простой вариант: атрибут шкаф_полка_N в сущности КНИГА. Дублирование данных и размещение слабо связано с книгой.

Вар. 2




Выделили сущность ШКАФ. Вроде исключили аномалии, связанные со шкафом.

Вар. 3




Исключили прямую связь книги с её местом хранения. Теперь сущность МЕСТО ссылается на книгу. Дублирование данных в этой сущности.

Вар. 4




Наиболее сложный, нормализованный и гибкий вариант.


Пример. Обновлённая ER-диаграмма ЛМД «Домашняя библиотека» (нотация RPT)



Пример. Обновлённая ER-диаграмма ЛМД «Домашняя библиотека» (draw.io)




Пример. Обновлённая ER-диаграмма КМД «Домашняя библиотека» (РРТ)



Пример. Обновлённая ER-диаграмма КМД «Домашняя библиотека» (draw.io)

Концептуальная и логическая модель данных "ДОМАШНЯЯ БИБЛИОТЕКА"



Какие знания по NF проверяются в РК1?

Для чего служит нормализация отношений?

Почему БД, как правило, содержит несколько таблиц?

Что можно сказать про состав полей таблицы?

Что можно сказать про порядок полей в таблице?

Что можно сказать про порядок строк в таблице?

В чём состоят требования 1NF?

Что такое составные и многозначные атрибуты?

Что такое наложенные атрибуты?

В чём состоят требования 2NF?

В чём состоят требования 3NF?

Что такое избыточность данных?

Аномалии изменения данных

Основные требования к содержанию таблиц данных.

Что такое денормализация отношений?

Для чего используется денормализация отношений?

Какие навыки по NF получите на практикуме?

1. Обнаруживать нарушения требований 1NF
2. Преобразовывать составные и многозначные атрибуты
3. Выявлять и устранять наложенные атрибуты
4. Проверять соответствия 2NF
5. Выявлять избыточность данных и аномалии их изменений
6. Проверять соответствия 3NF
7. Применять денормализацию отношений.

**Терпения и удачи всем,
кто связан с моделями данных**

Спасибо за внимание!

ВАЛЕРИЙ ИВАНОВИЧ АРТЕМЬЕВ

МГТУ имени Н.Э. Баумана, кафедра ИУ-5

тел.: +7(985) 365-79-86

e-mail: viart@bmstu.ru