Модели данных

B2. Универсальные модели. EAV



Московский государственный технический университет
имени Н.Э. Баумана

Факультет ИБМ

сен 2024 – ноя 2025 года

Москва

Артемьев Валерий Иванович © 2024-25

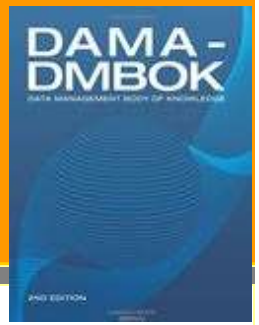
9. Универсальные модели данных. Модели «сущность – атрибут – значение»

Актуализировать, когда устоится

- Что такое универсальная модель данных?
- Переход к метамоделям и денормализация
- Сценарии применения
- Широкие таблицы
- Узкие таблицы
- Модели «сущность – атрибут – значение» EAV
- Варианты реализации модели EAV
- Пример финансовой отчётности
- Пример магазина с широкой номенклатурой товаров
- Достоинства и недостатки модели EAV
- Альтернативы: применение XML / JSON

Вопросы для самопроверки

Что такое архитектура данных?





Архитектура данных образует фундамент управления данными. Удовлетворяет насущную потребность в их представлении на разных уровнях абстракции так, чтобы они были понимаемы бизнесом и руководство могло принимать относительно этих данных соответствующие решения.

Архитектура данных включает:

- **Корпоративная модель данных**
- **Схемы потоков данных и их преобразований**

Корпоративная модель данных

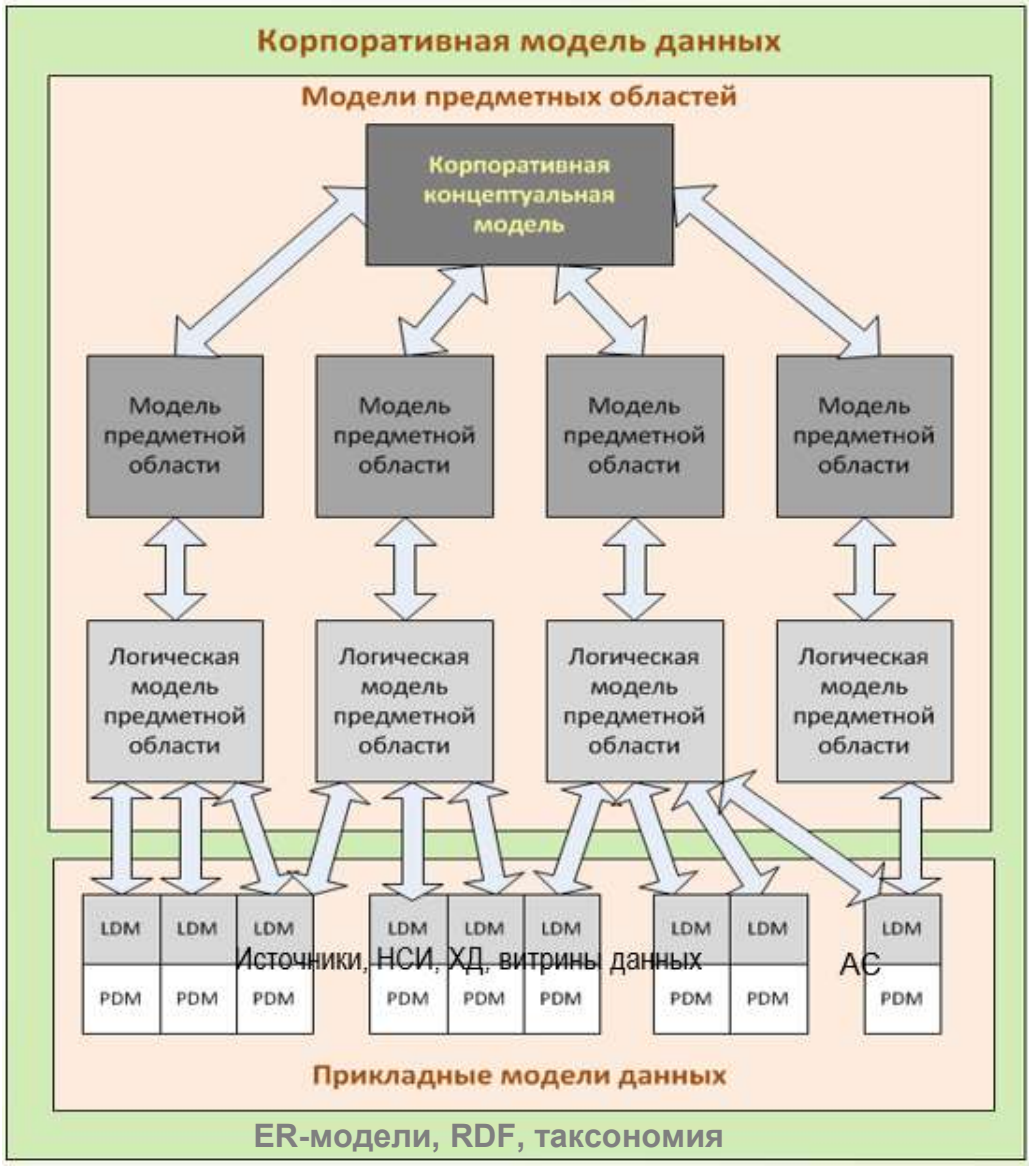
Здесь широко используются универсальные модели данных

Концептуальный обзор всех предметных областей корпорации

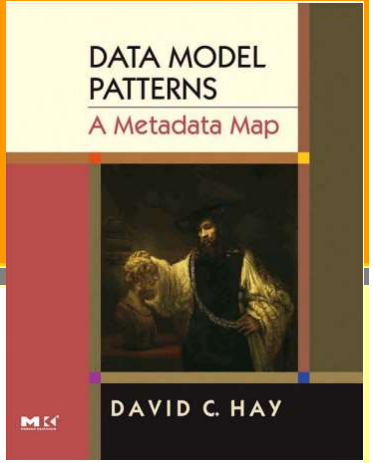
Концептуальное представление сущностей и связей для каждой предметной области

Логическое представление для каждой предметной области

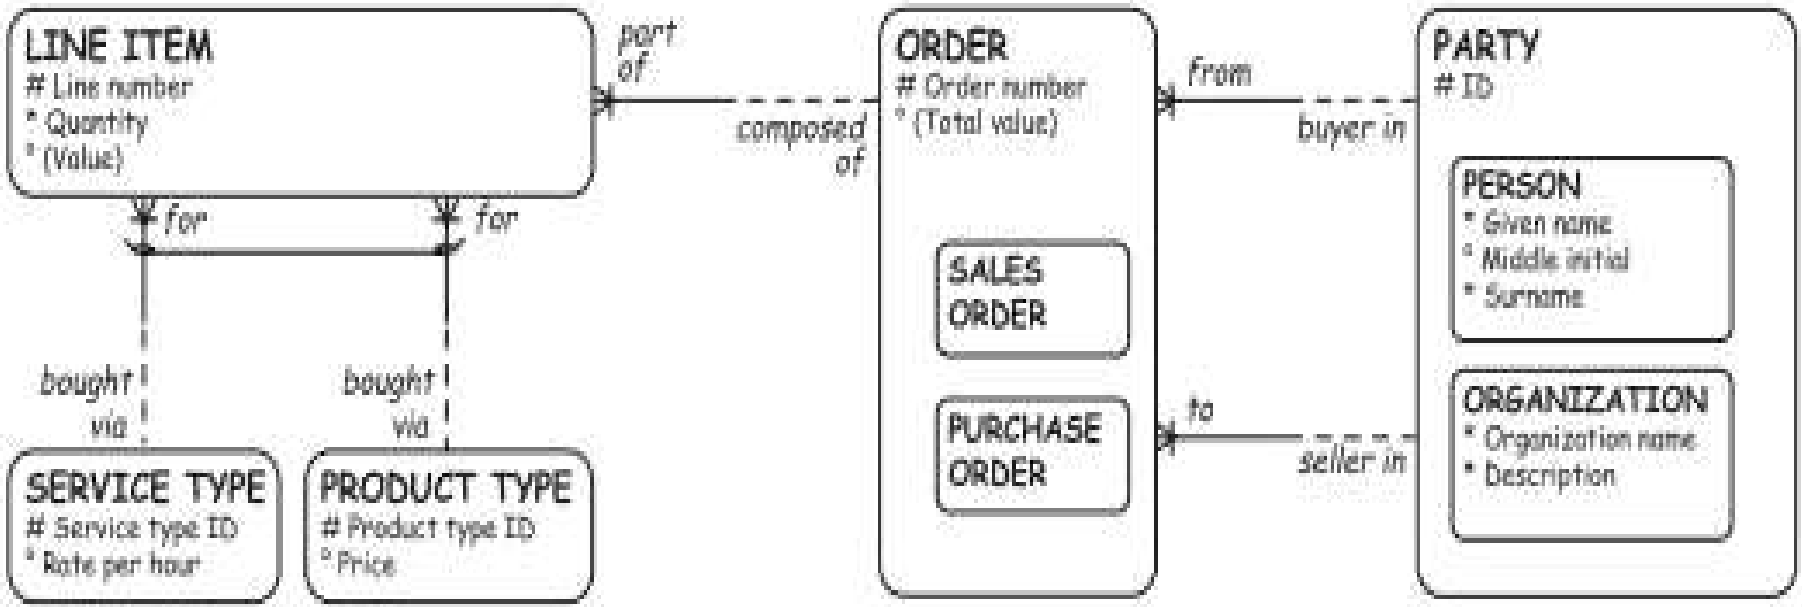
Подробные логические и физические модели данных, специфичные для реализации приложений или проектов



Моделирование предметных областей

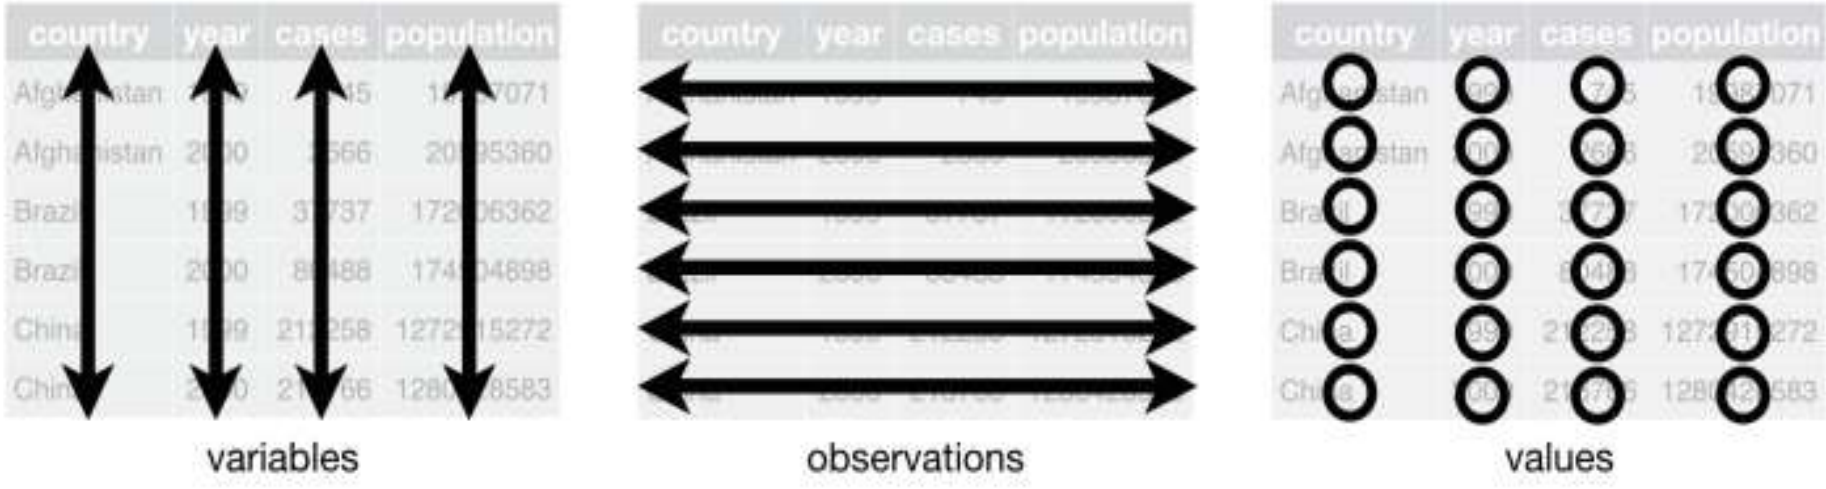


Универсальные модели важны для описания предметных областей



Традиционные модели данных

- Ориентированы на создание БД для *узкого применения*
- *Затрудняют адаптацию* структуры и состава данных
- Добавление атрибута или сущности *приводит к реорганизации* схемы
- *Нельзя использовать* модель *для разных предметных областей*
- *Специализированы* для предметной области и *неуниверсальны*:
  - определённой бизнес-сущности соответствует таблица
  - каждый экземпляр сущности – запись в таблице
  - каждый атрибут экземпляра сущности – колонка таблицы
  - каждое значение – в своей ячейке таблицы.



Появилась потребность в более гибких структурах данных, в частности, для накопления данных в хранилищах данных

Что такое универсальная модель данных?

УМД

Универсальная модель данных (УМД) представляет собой стандартную реляционную модель для гибкого представления разных наборов данных и / или определённые приёмы метамоделирования с помощью стандартных компонентов.

Два основных вида УМД:

1. Создание и расширение УМД с *фиксированным набором таблиц* требует только добавления новых записей в существующие таблицы без изменения структуры данных.
2. Создание и расширение УМД путём соединения *типовых компонентов метамодели по определённым правилам*.

Возможности и особенности УМД

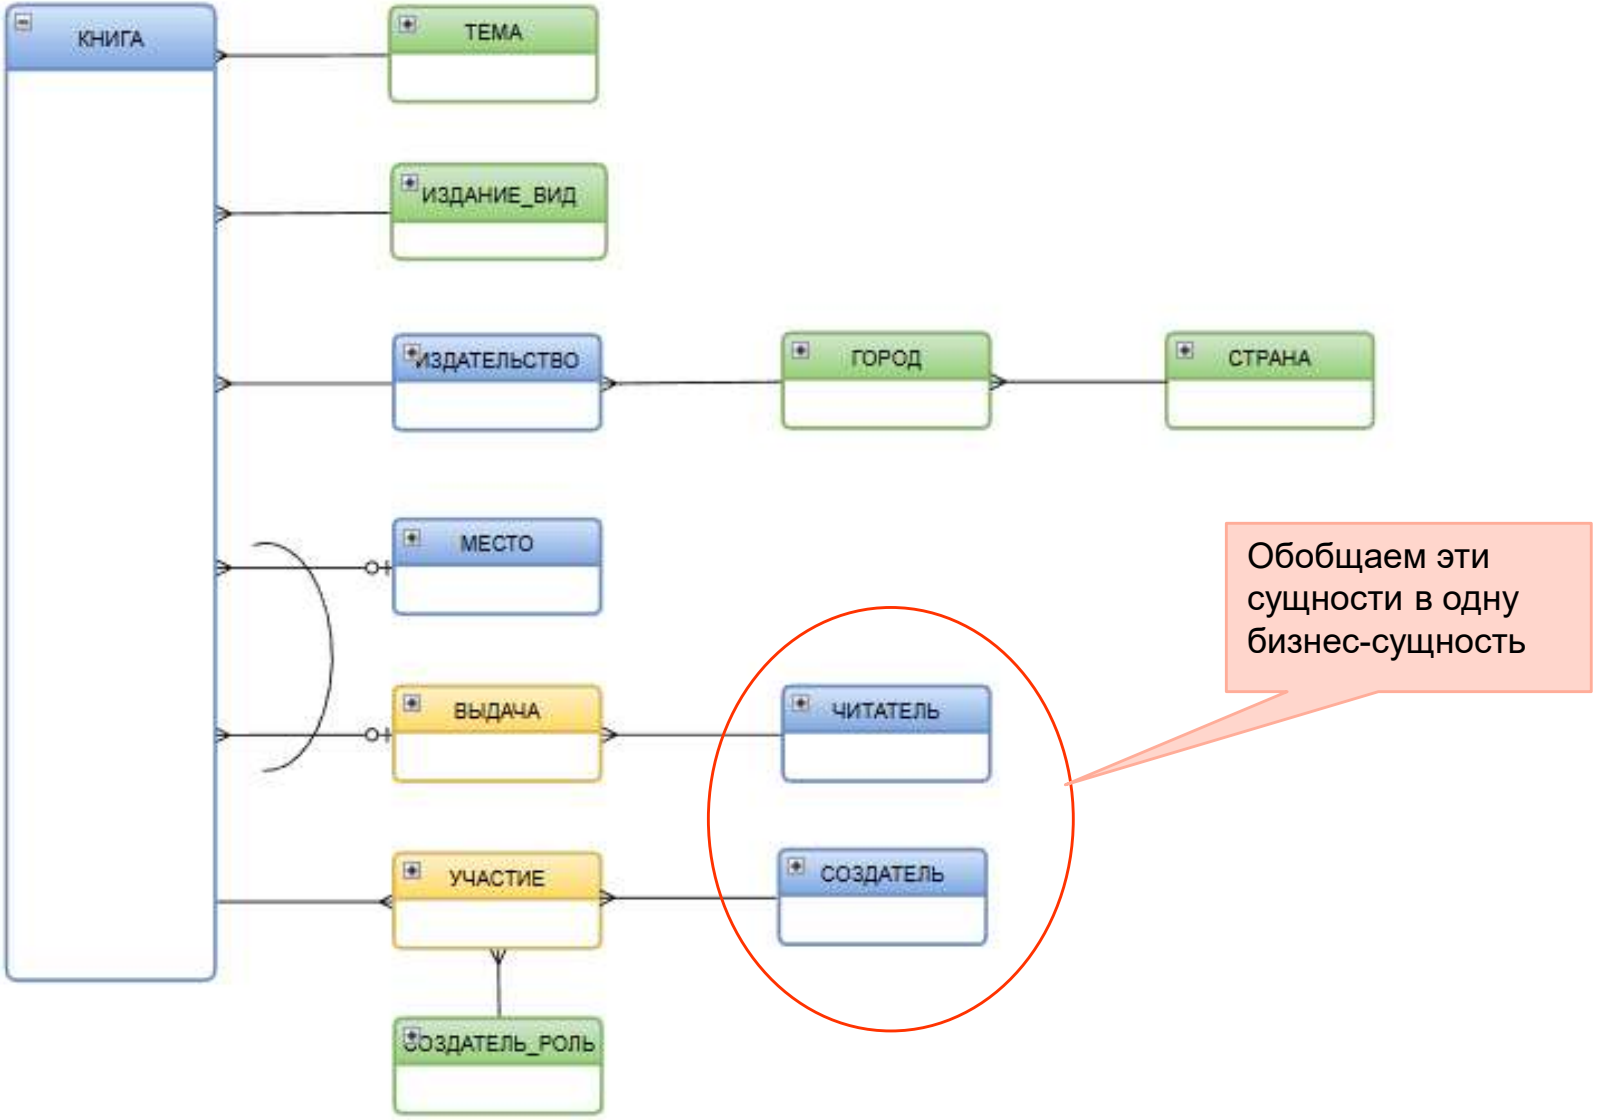
- Результат стандартизации моделей данных
- Обобщение традиционных моделей данных
- Переход к метамоделям данных
- Структура может не зависеть от набора данных
- Настройка для разных предметных областей
- Прототипирование решений по БД
- Сокращению затрат на создание / развитие БД
- Специализация в противоположность обобщению.

Приёмы стандартизации и обобщения моделей данных УМД

- Обобщение подобных бизнес-сущностей путём объединения в общую бизнес-сущность
- Стандартизация линейных классификаторов путём объединения в один справочник
- Стандартизация иерархических справочников в виде рекурсивных моделей данных
- Обобщение связей бизнес-сущностей путём их замены кросс-сущностями.

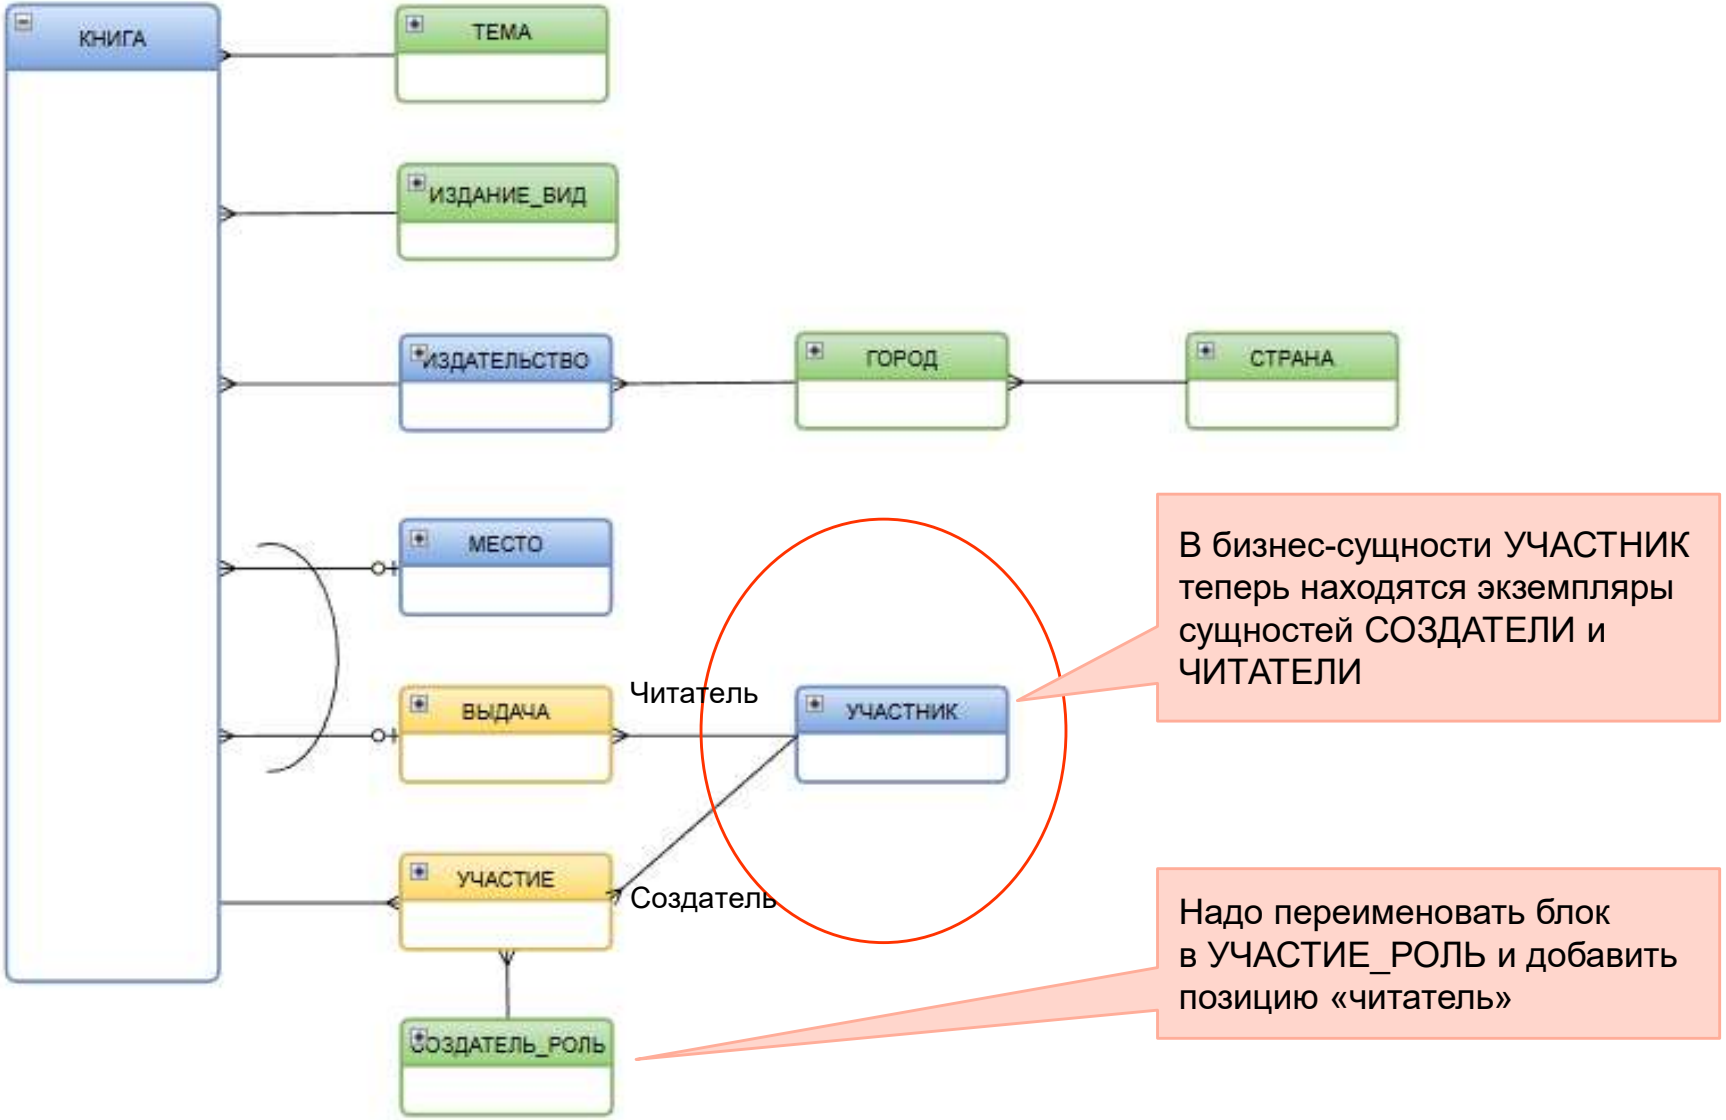
Обобщение подобных бизнес-сущностей (1)

УМД



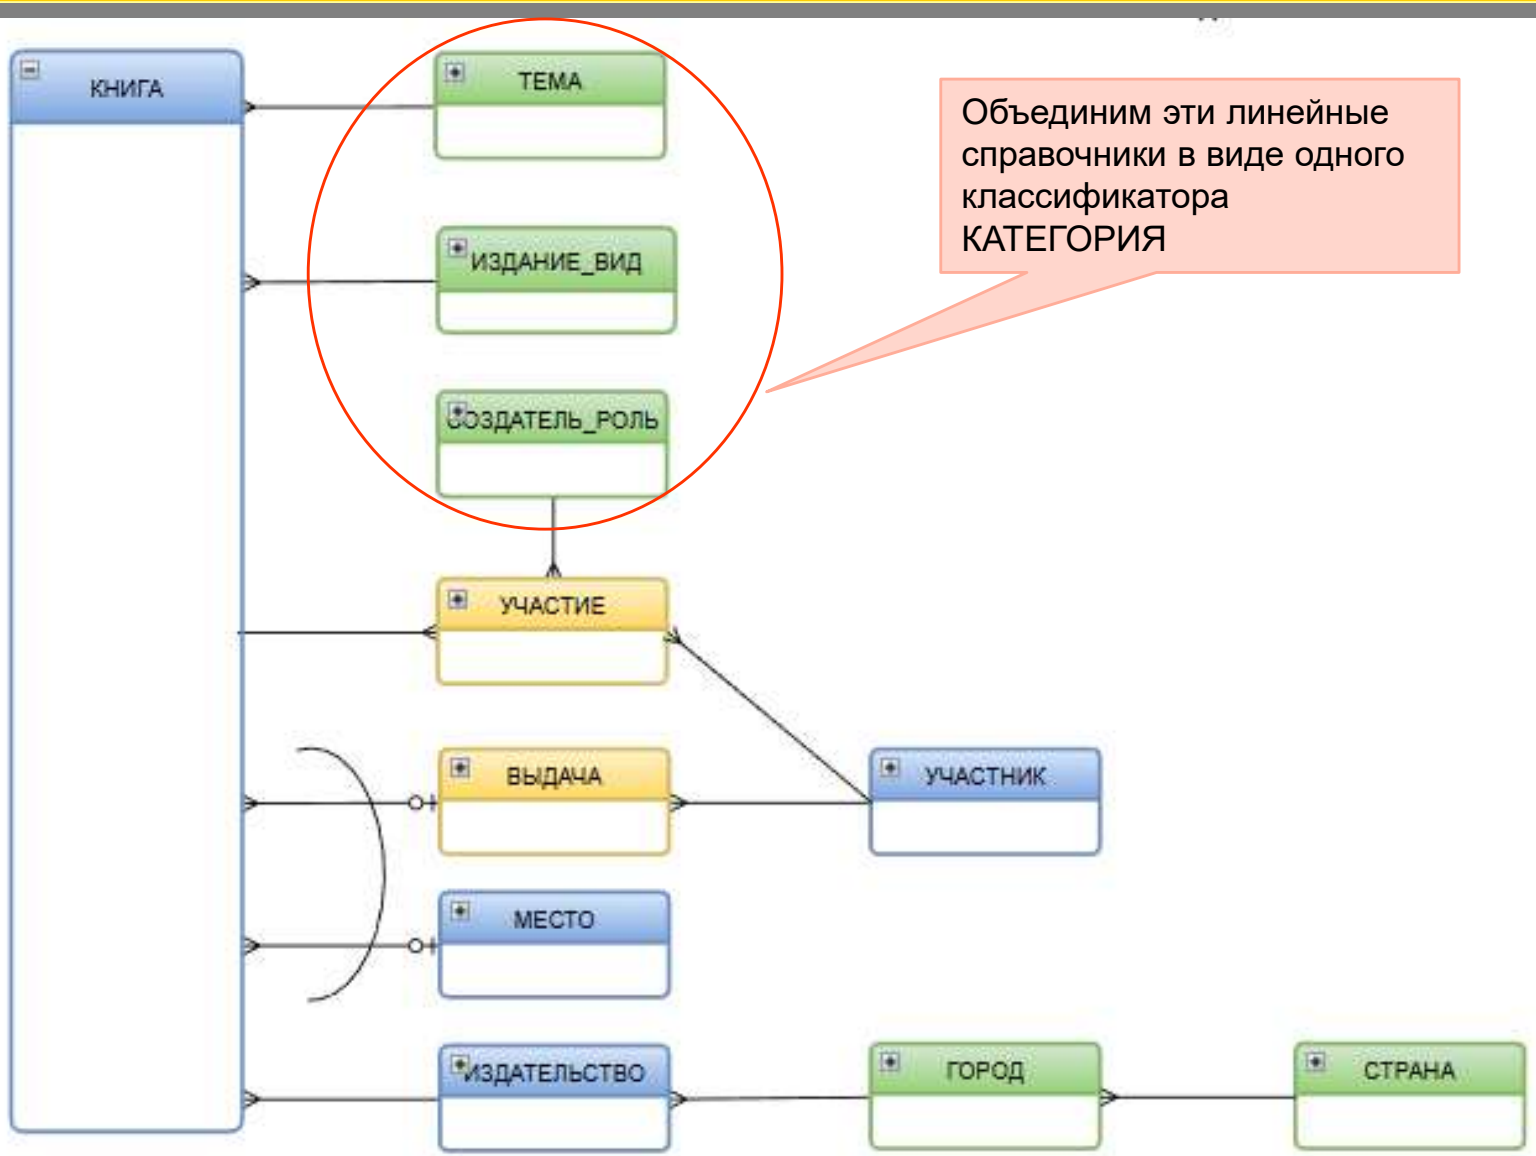
Обобщение подобных бизнес-сущностей (2)

УМД



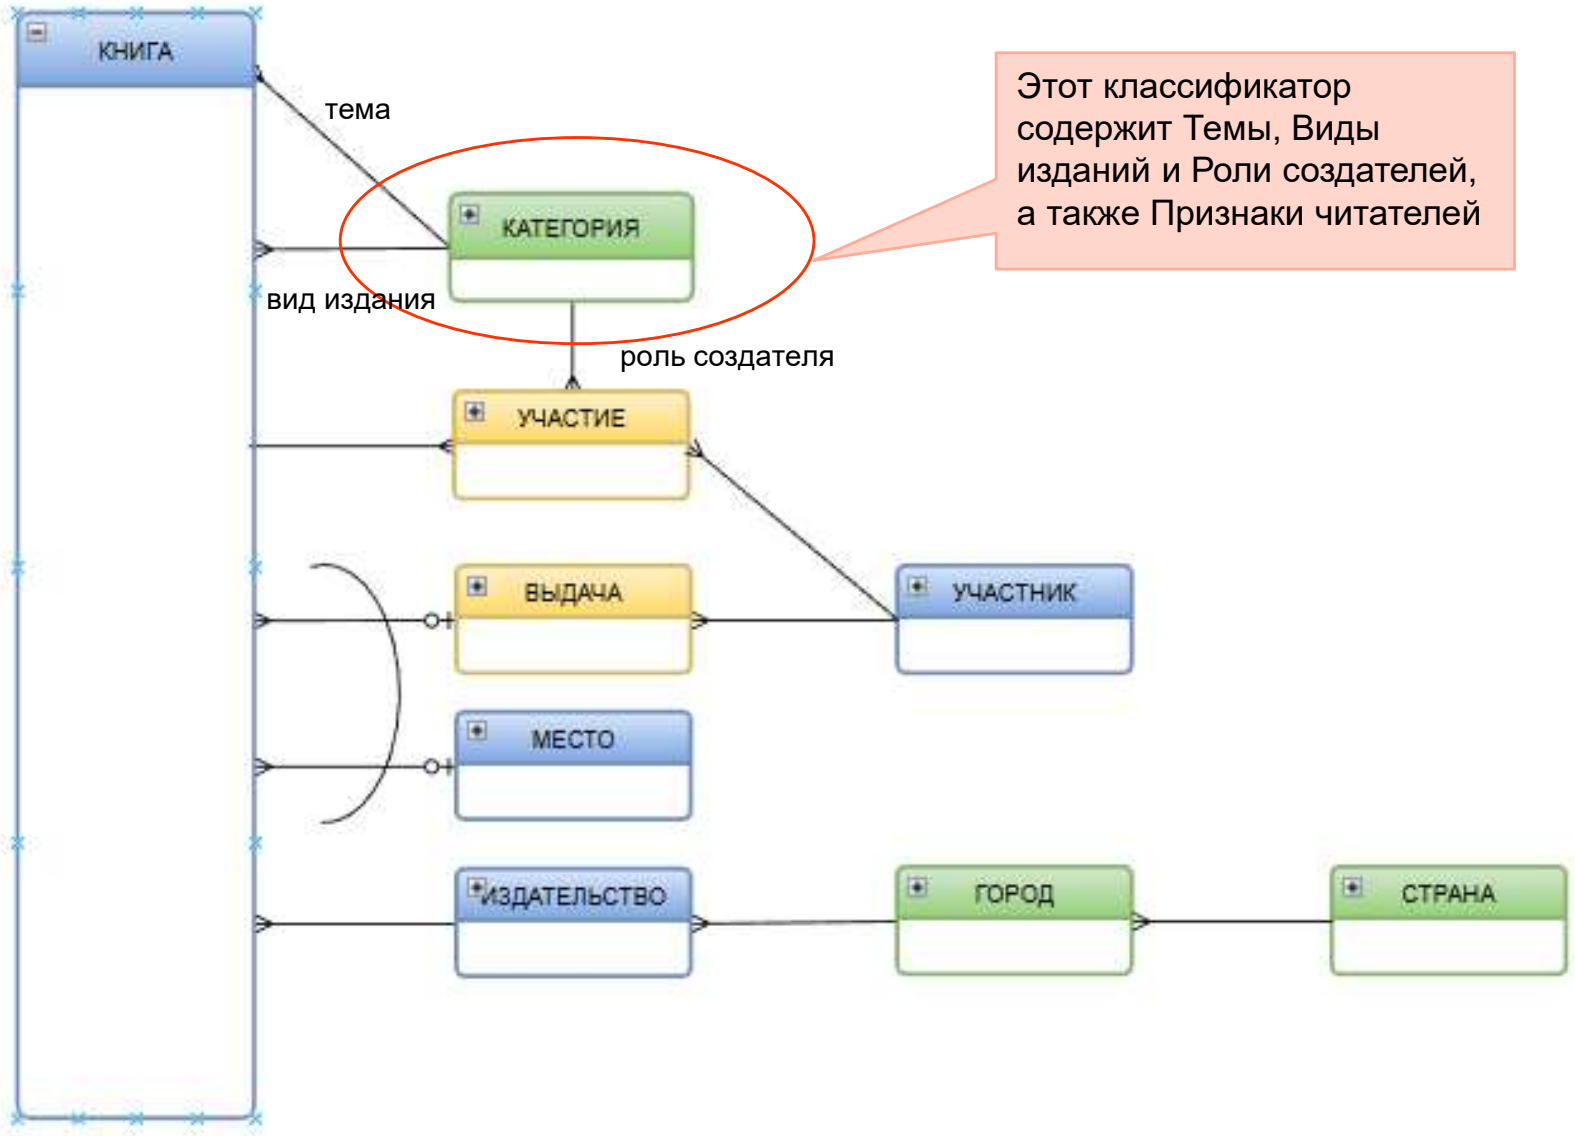
Стандартизация: объединение линейных справочников (1)

УМД

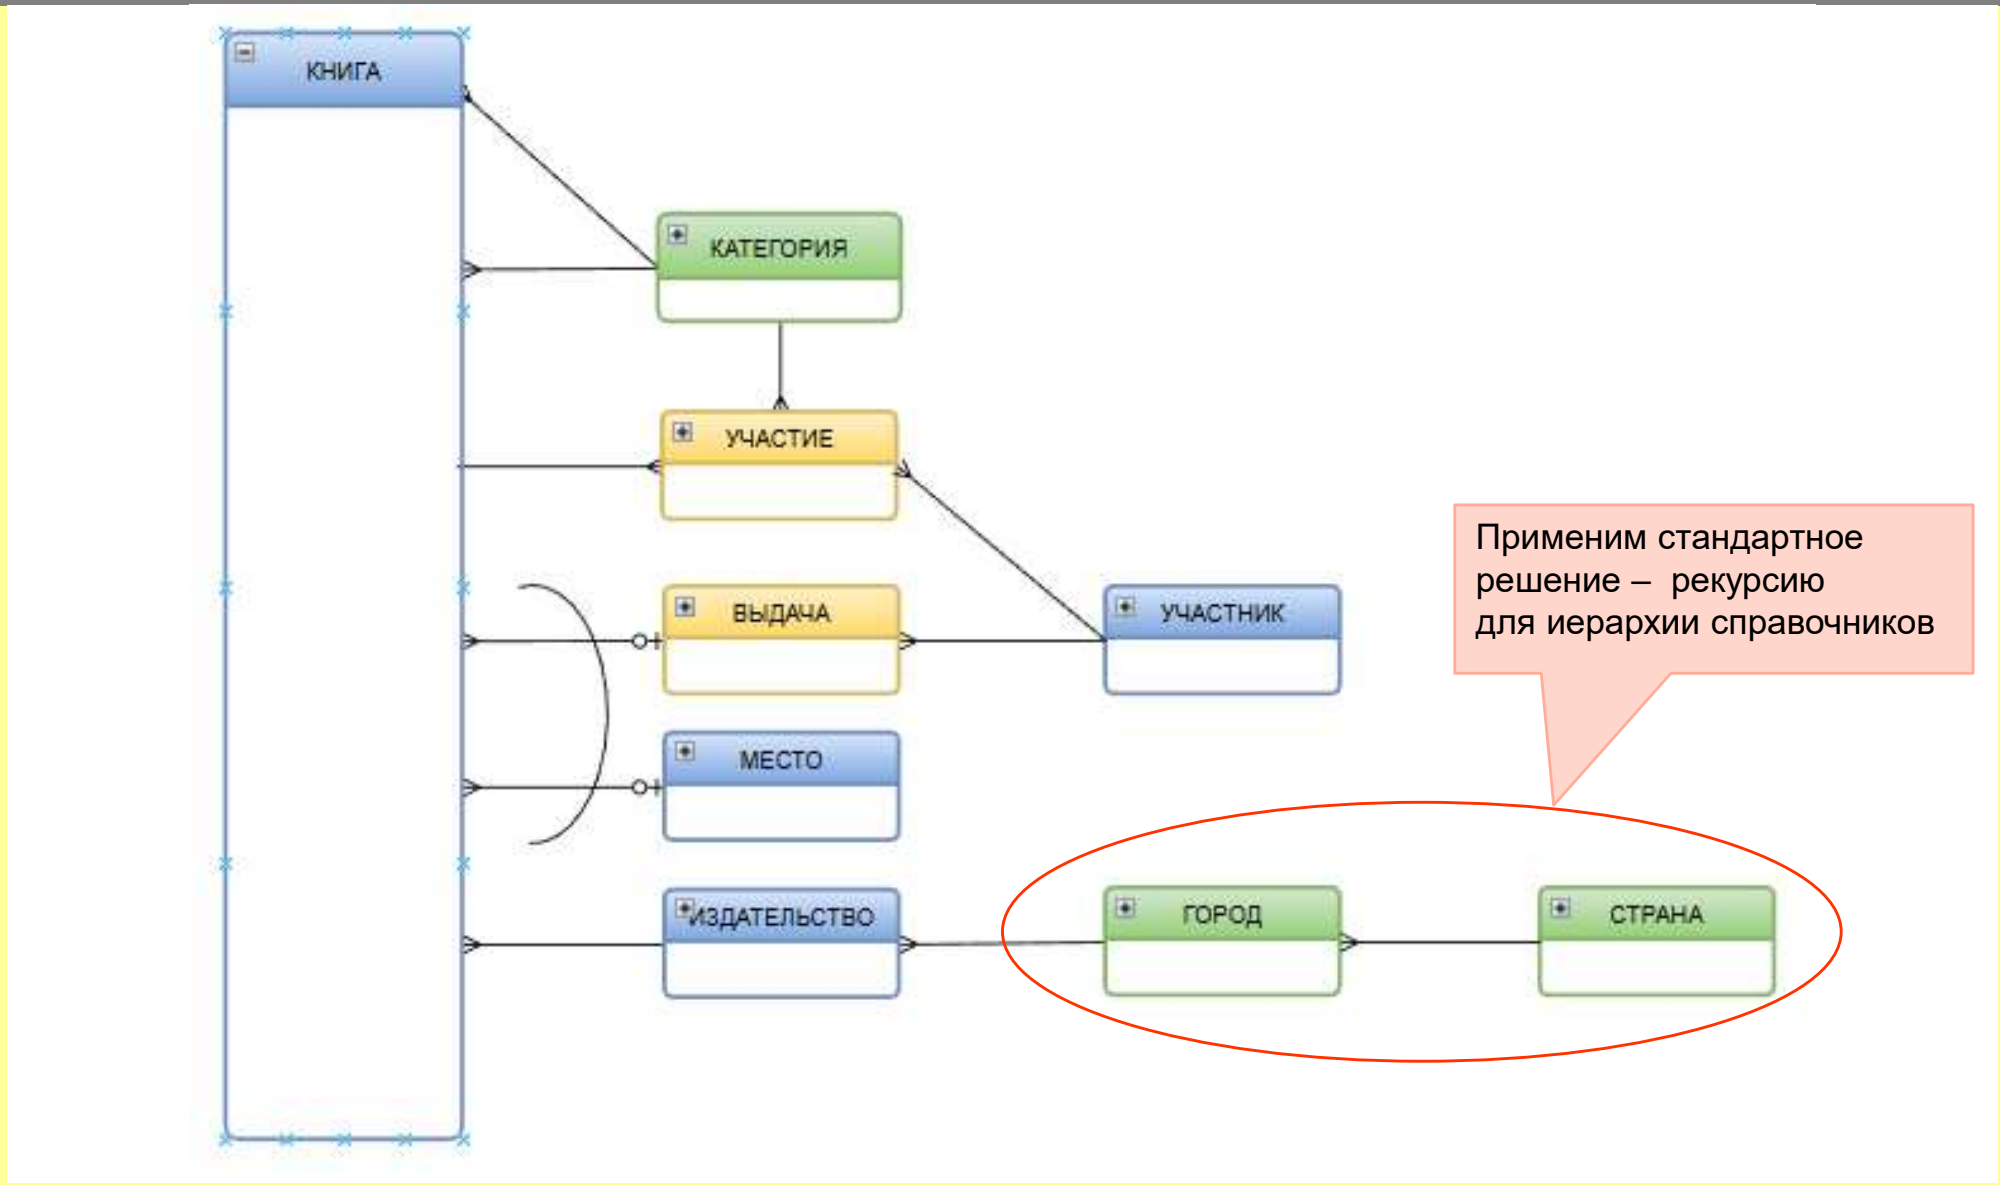


Стандартизация: объединение линейных справочников(2)

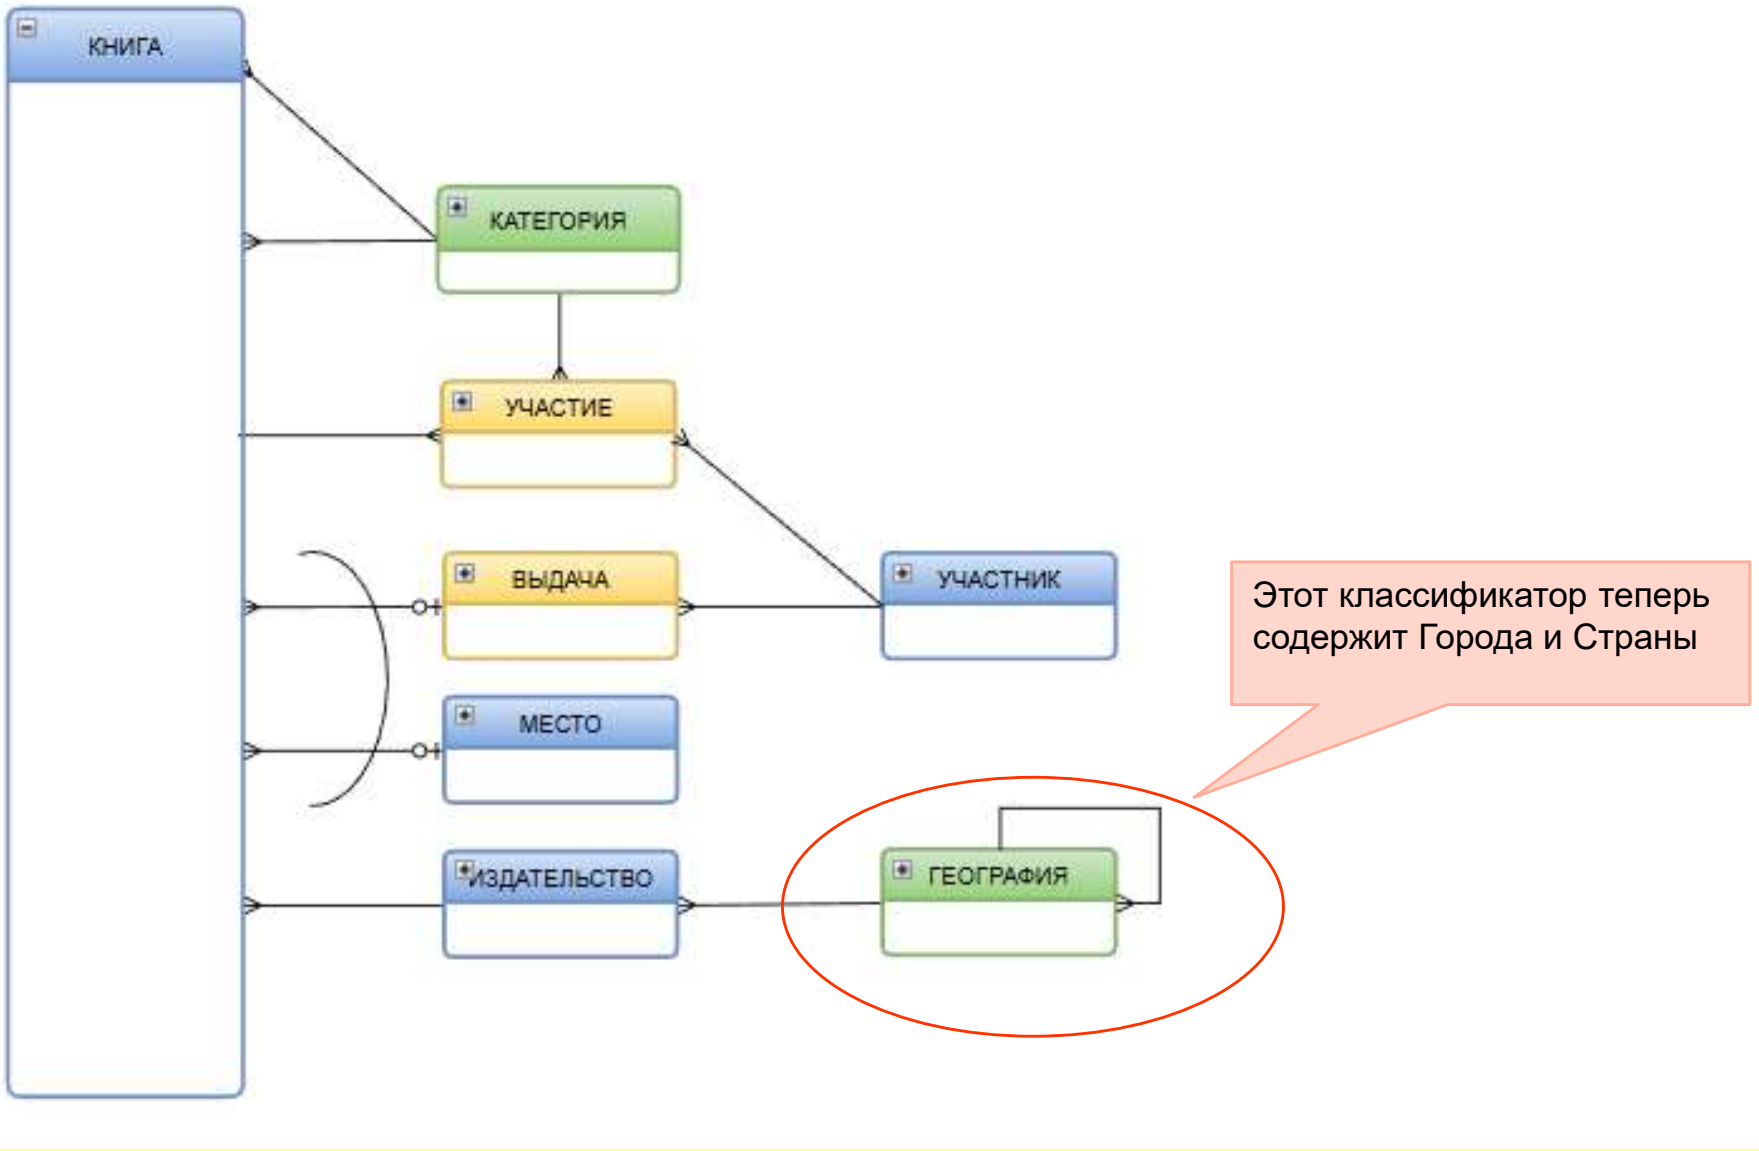
УМД



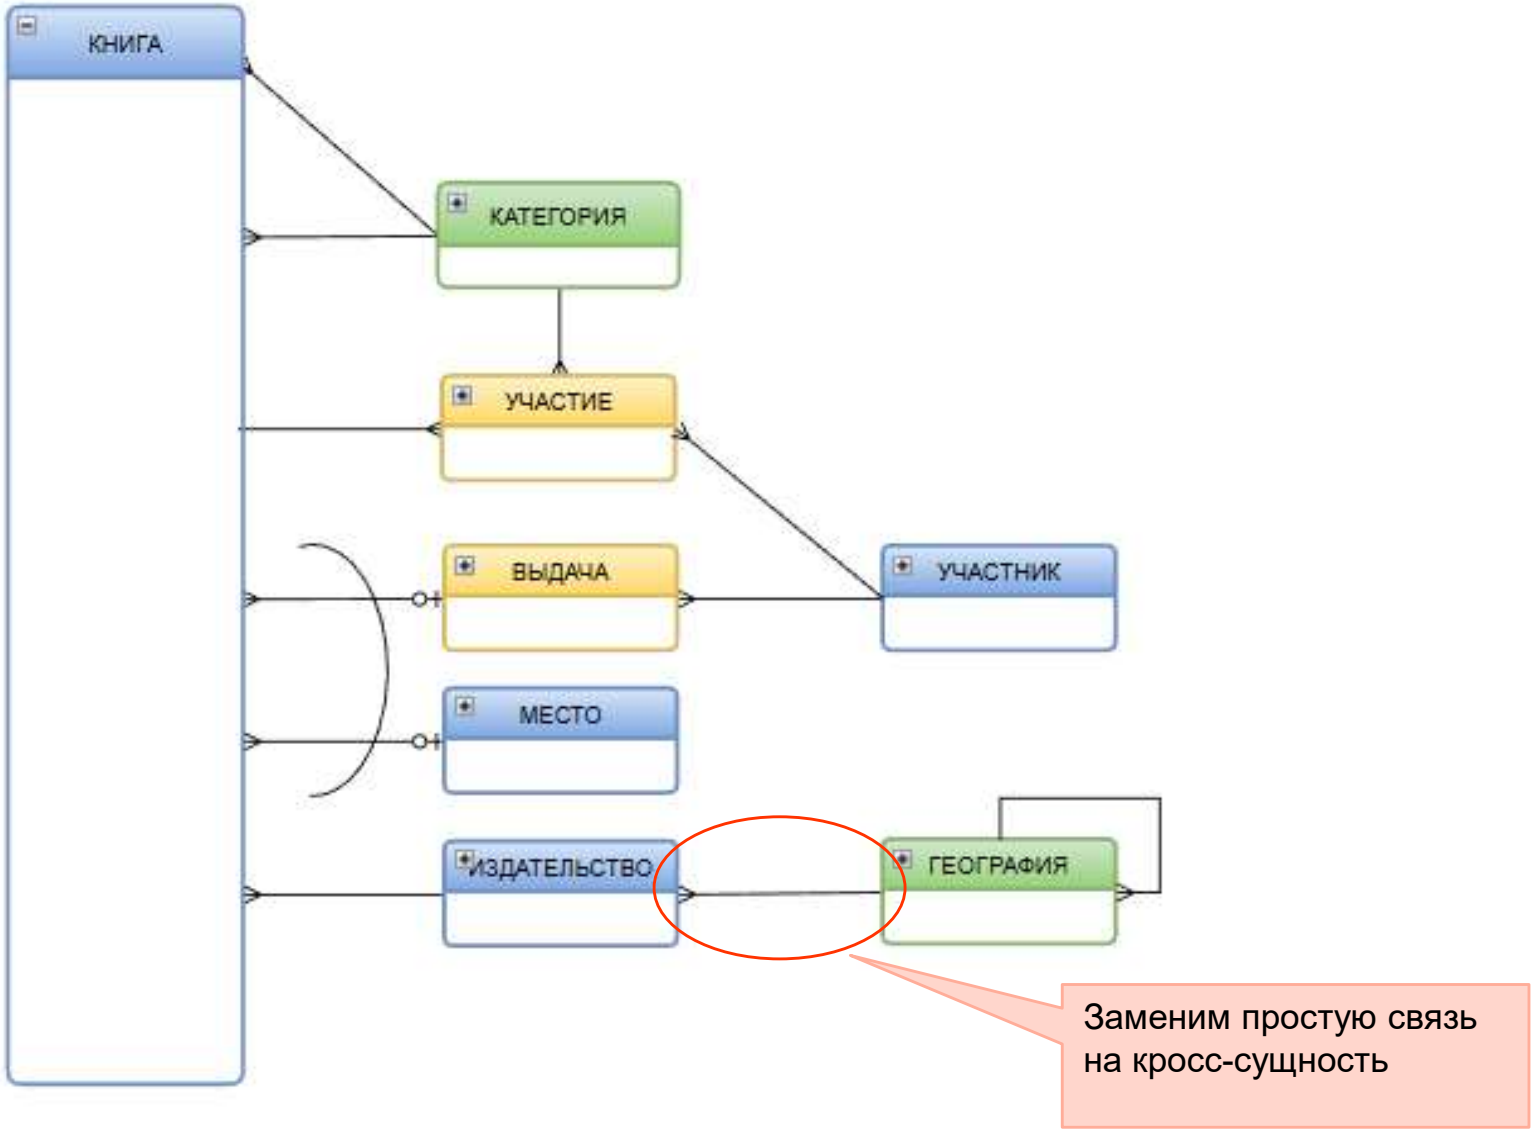
Стандартизация: рекурсии для иерархии справочников (1)



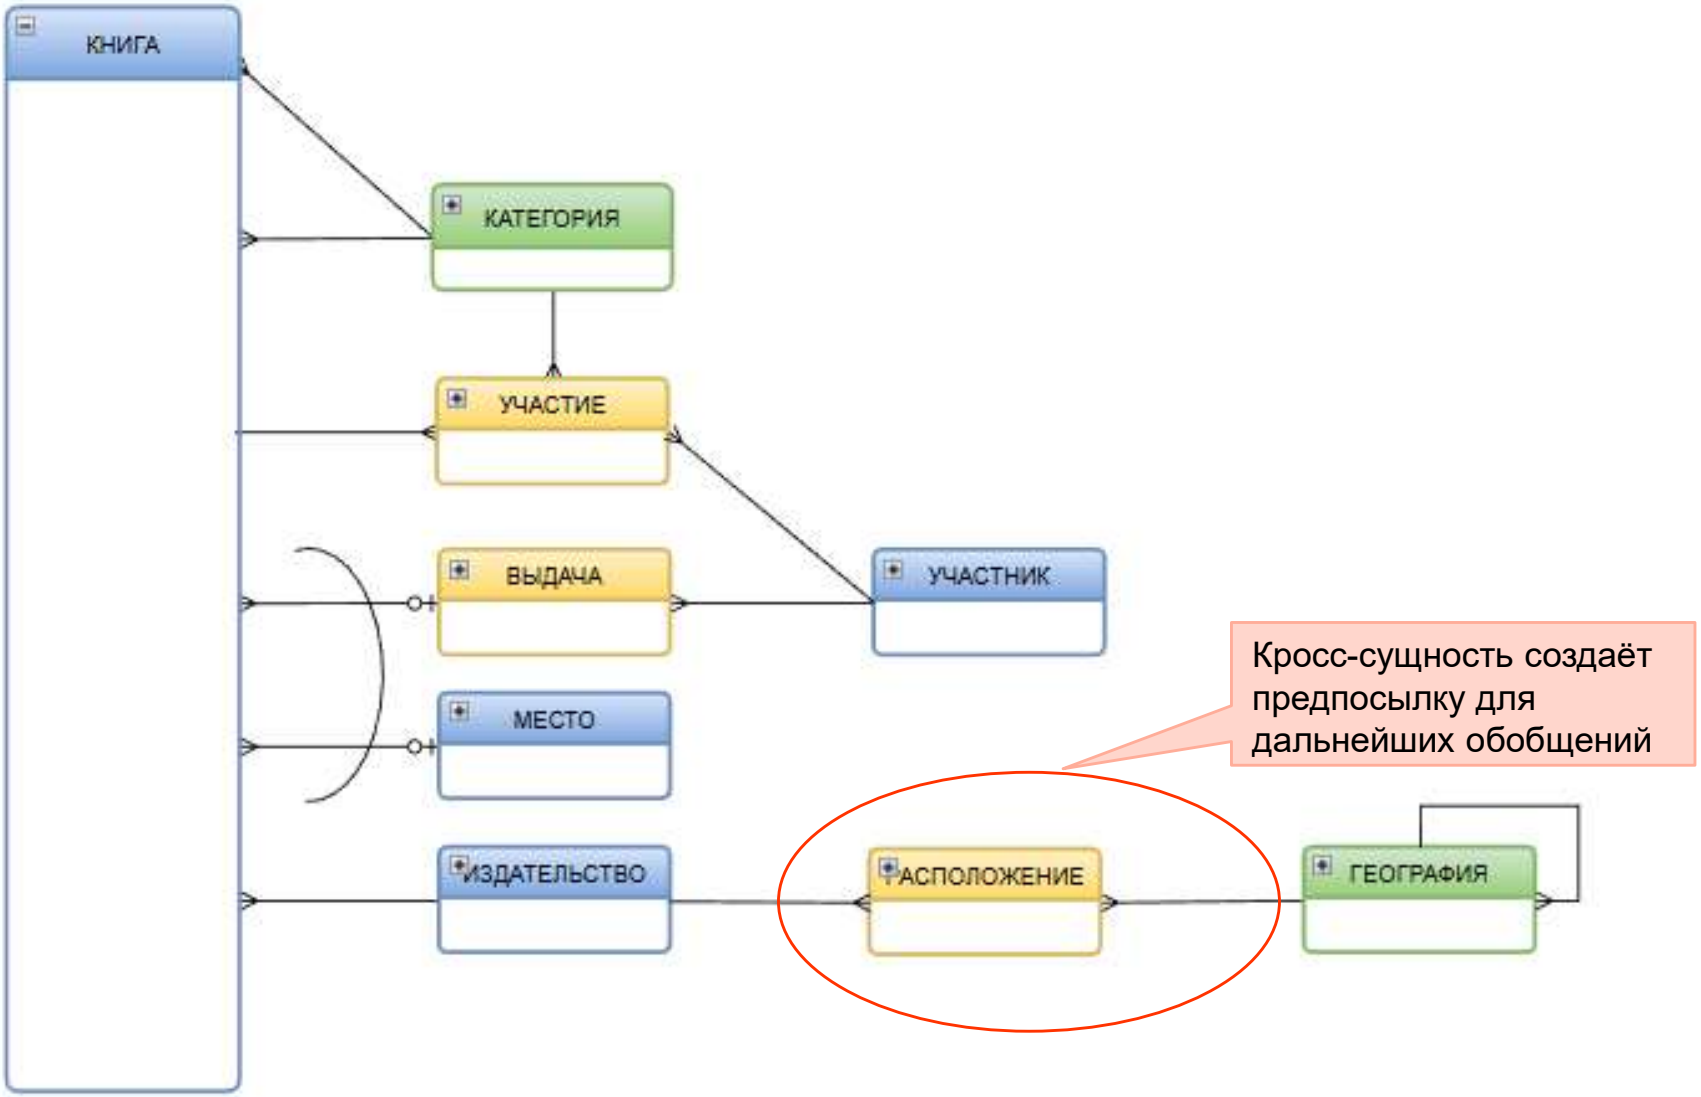
Стандартизация: рекурсия для иерархии справочников (2) УМД



Кросс-сущности для связи (1) УМД

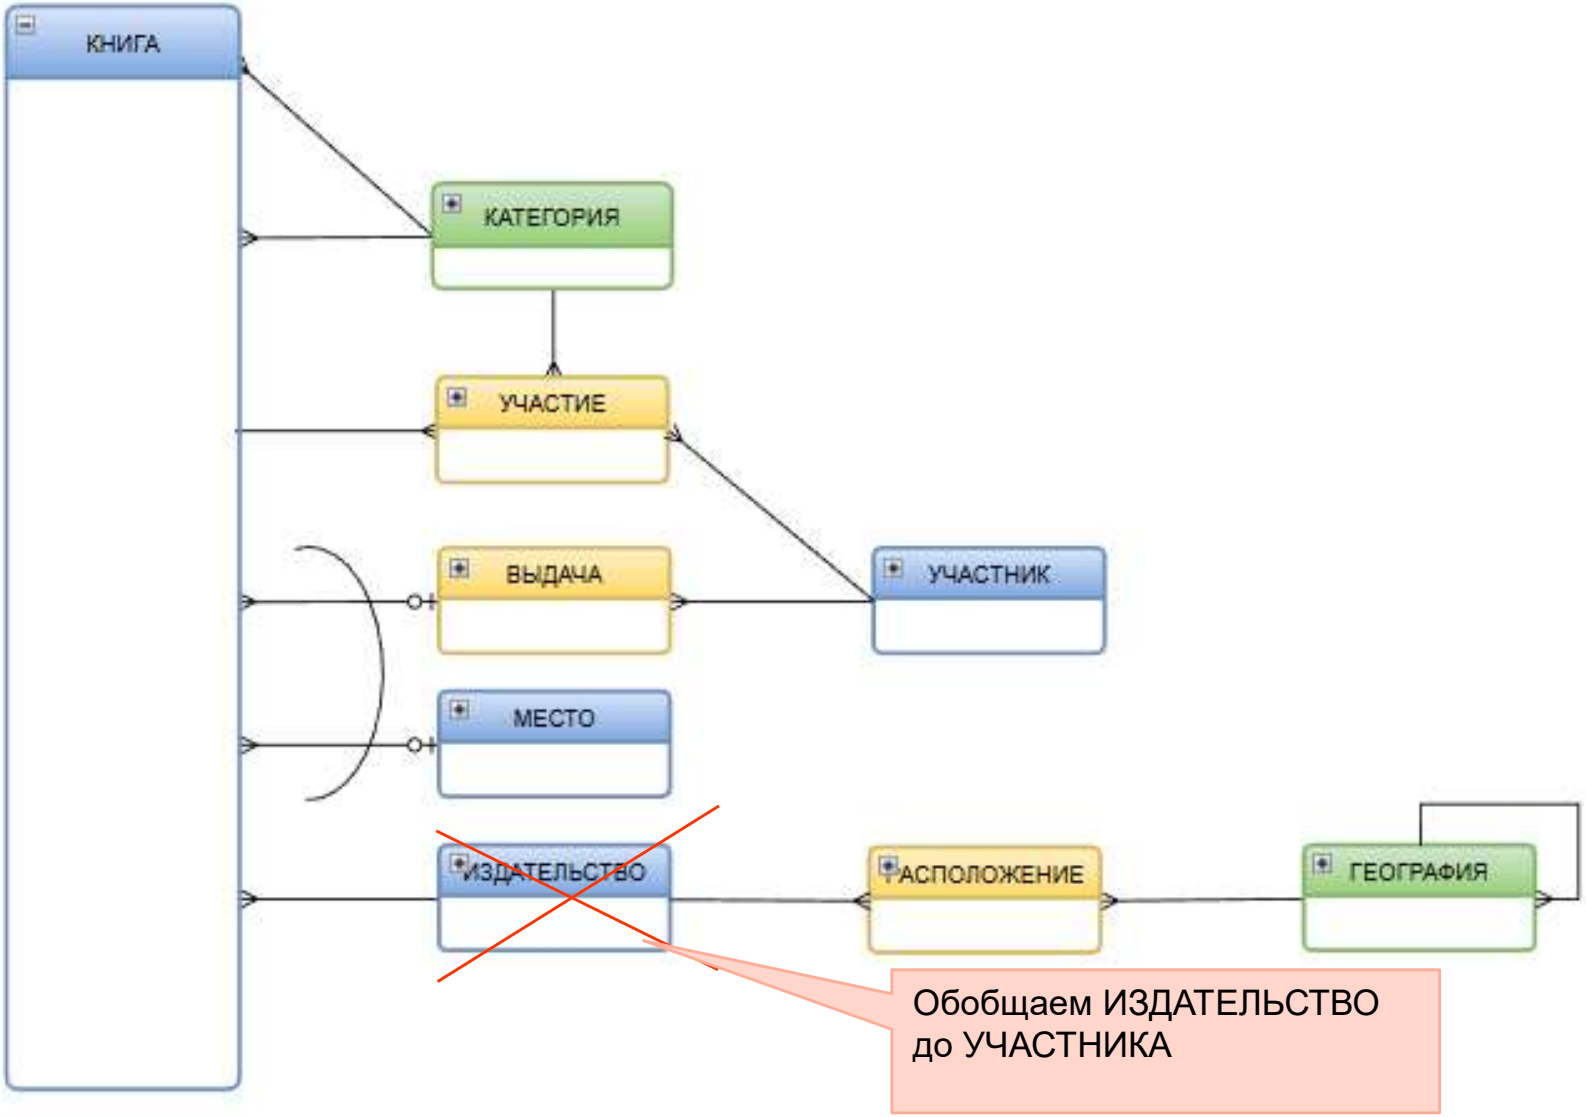


Кросс-сущности для связи (2) УМД



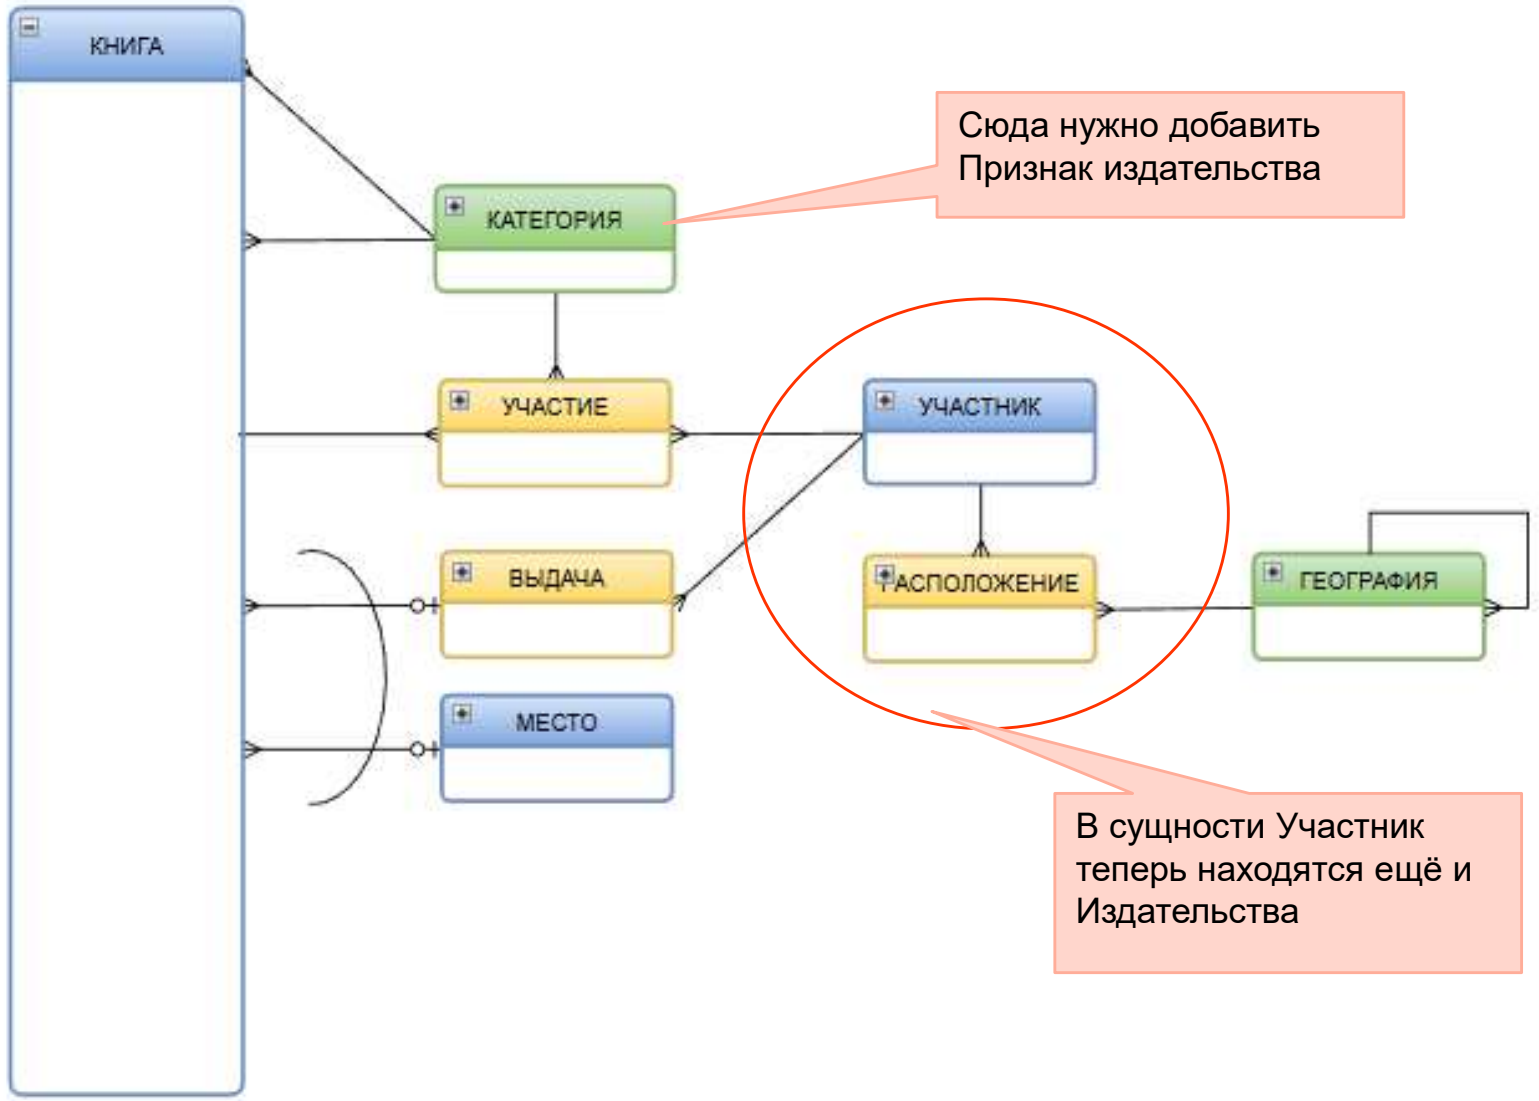
Обобщение подобных бизнес-сущностей (3)

УМД



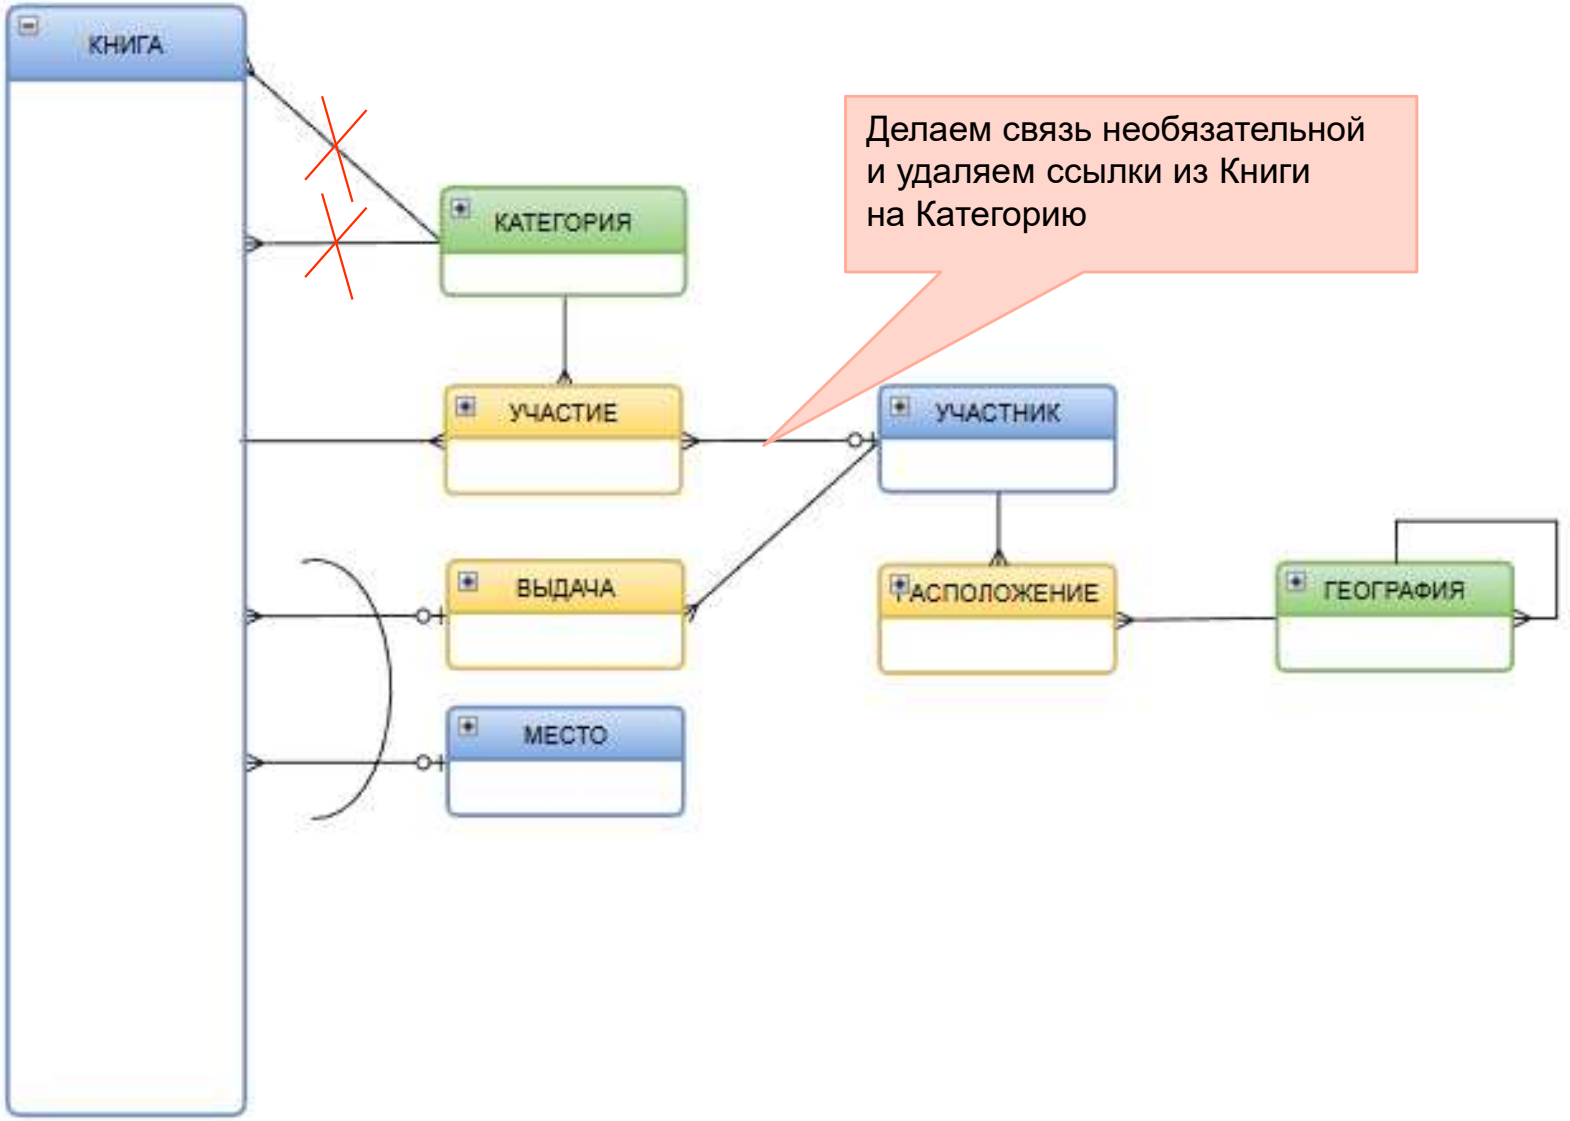
Обобщение подобных бизнес-сущностей (4)

УМД



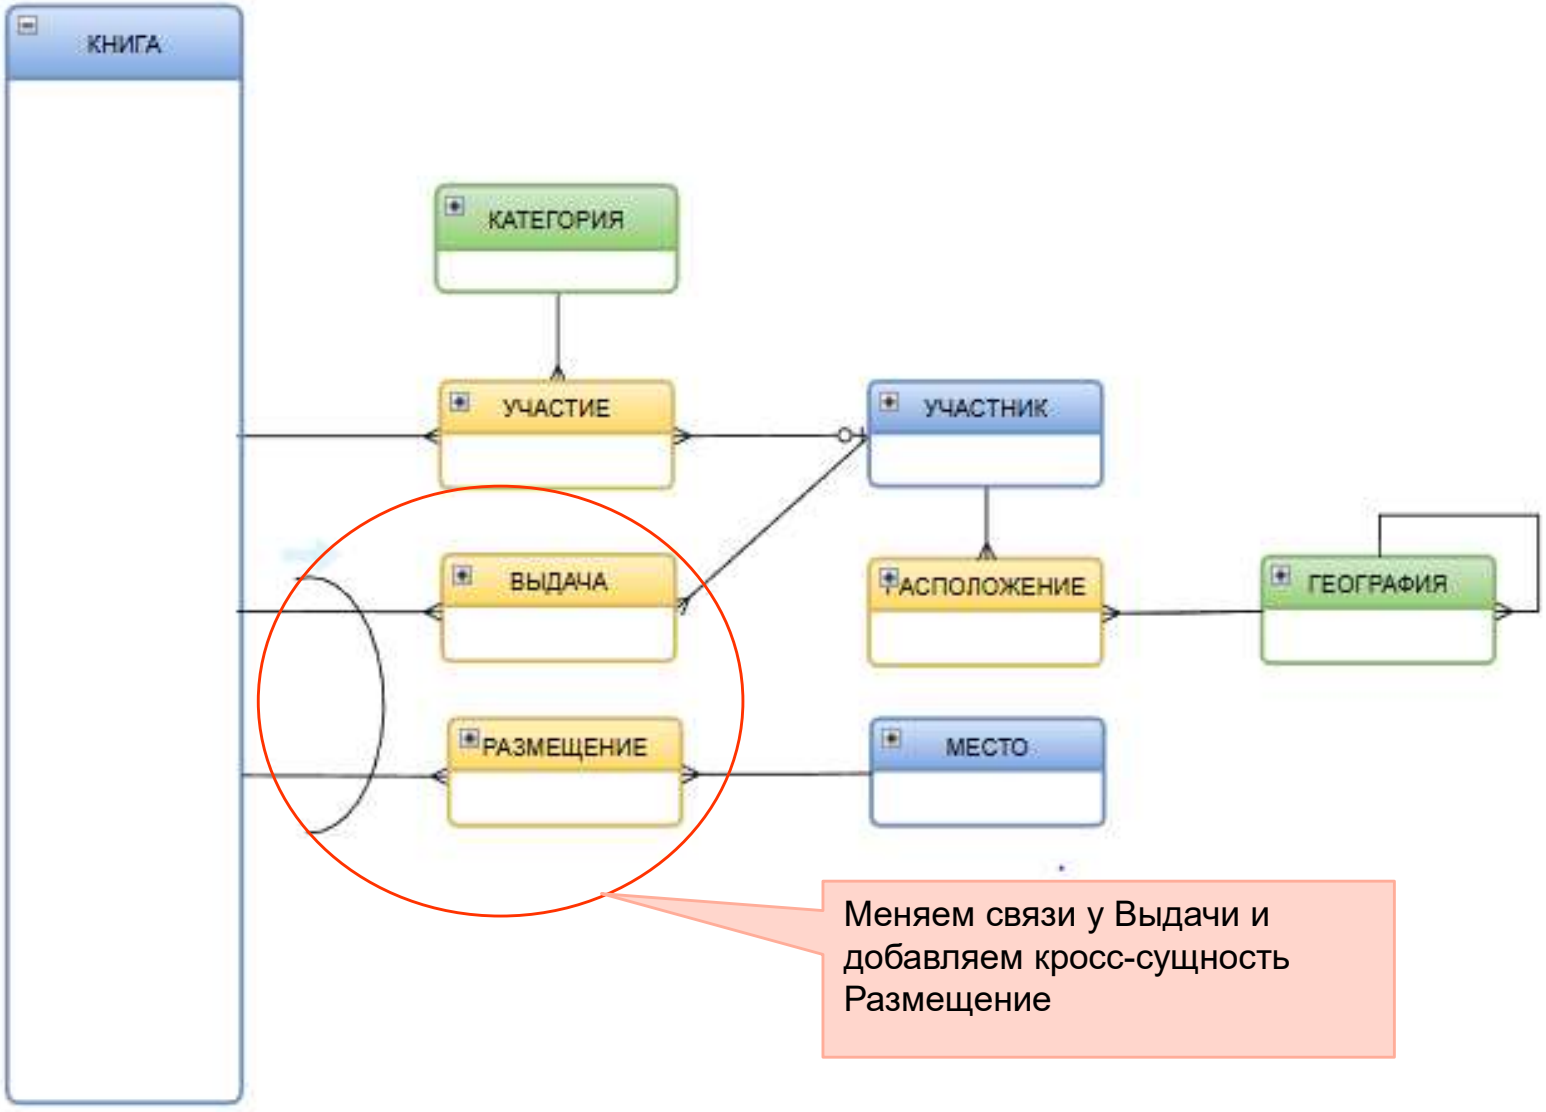
Обеспечение независимости бизнес-сущности КНИГА (1)

УМД



Обеспечение независимости бизнес-сущности КНИГА (2)

УМД



Результаты обобщения и стандартизации КМД «Домашняя библиотека»

УМД



Характеристика	Начальный вариант	Конечный вариант
Сущностей	12	9 ↓
независимых сущностей	7	5
зависимых сущностей	5	4
классификаторов	5	2
реестров	5	3
кросс-сущностей	2	4 ↑
Связей	11	10

Меньше сущностей в итоге
Больше кросс-сущностей
Число связей почти не изменилось

Достоинства и недостатки приёмов стандартизации и обобщения моделей

УМД

Повышение уровня абстракции моделей данных важно для интегрированных информационных ресурсов

Унификация представления справочников при их стандартизации

Уменьшение числа справочников и реестров за счёт стандартизации и обобщения бизнес-сущностей

Уменьшение числа независимых сущностей из-за замены связей кросс-сущностями

Гибкость моделей данных за счёт расширения унифицированных справочников, добавления и изменение связей через кросс-сущности.

Ухудшение понимания структуры данных из-за повышения уровня абстракции

Нарушение нормализации данных за счёт наложенных атрибутов справочников и реестров

Увеличение числа кросс-сущностей приводит к таким последствиям:

- **затруднение их ведения**
- **усложнение запросов выборки**

Снижение производительности:

- из-за громоздких и рекурсивных справочников
- из-за сложных соединений сущностей через кросс-сущности.

Рассмотренные приёмы оправданы при неопределённых или постоянно изменяющихся структурах данных

Какие знания по универсальной модели данных проверяются в РК2?

УМД

1. Что такое универсальная модель данных?
2. Возможности и особенности УМД
3. Приёмы стандартизации и обобщения модели данных
4. Пример обобщения подобных сущностей
5. Пример стандартизации: объединение справочников
6. Пример стандартизации: рекурсия иерархии справочников
7. Пример обобщения связей за счёт кросс-сущностей
8. Результаты обобщения и стандартизации модели данных
9. Достоинства и недостатки универсализации моделей данных

Модели «сущность – атрибут – значение» (Entity-Attribute-Value) EAV

Универсальная модель данных с фиксированным набором таблиц для гибкого представления переменного (неопределённого) состава атрибутов - свойств одной сущности или для объединения сущностей, различающихся атрибутами - свойствами.

Модель оптимизирована для эффективного хранения разреженных матриц или набора неопределённых свойств или значений данных.
Другие названия *вертикальная модель* данных или *открытая схема.*

Сценарии применения EAV

Неопределённый или переменный состав атрибутов сущности предметной области

- Пример 1. Химические анализы минералов
- Пример 2. Состав продуктов питания
- Пример 3. Состав финансовой отчётности
- Пример 4. Медицинская диагностика

Объединение сущностей, различающихся атрибутами

- Пример 5. Ассортимент товаров в магазине
- Пример 6. Работа с разными типами клиентов компании

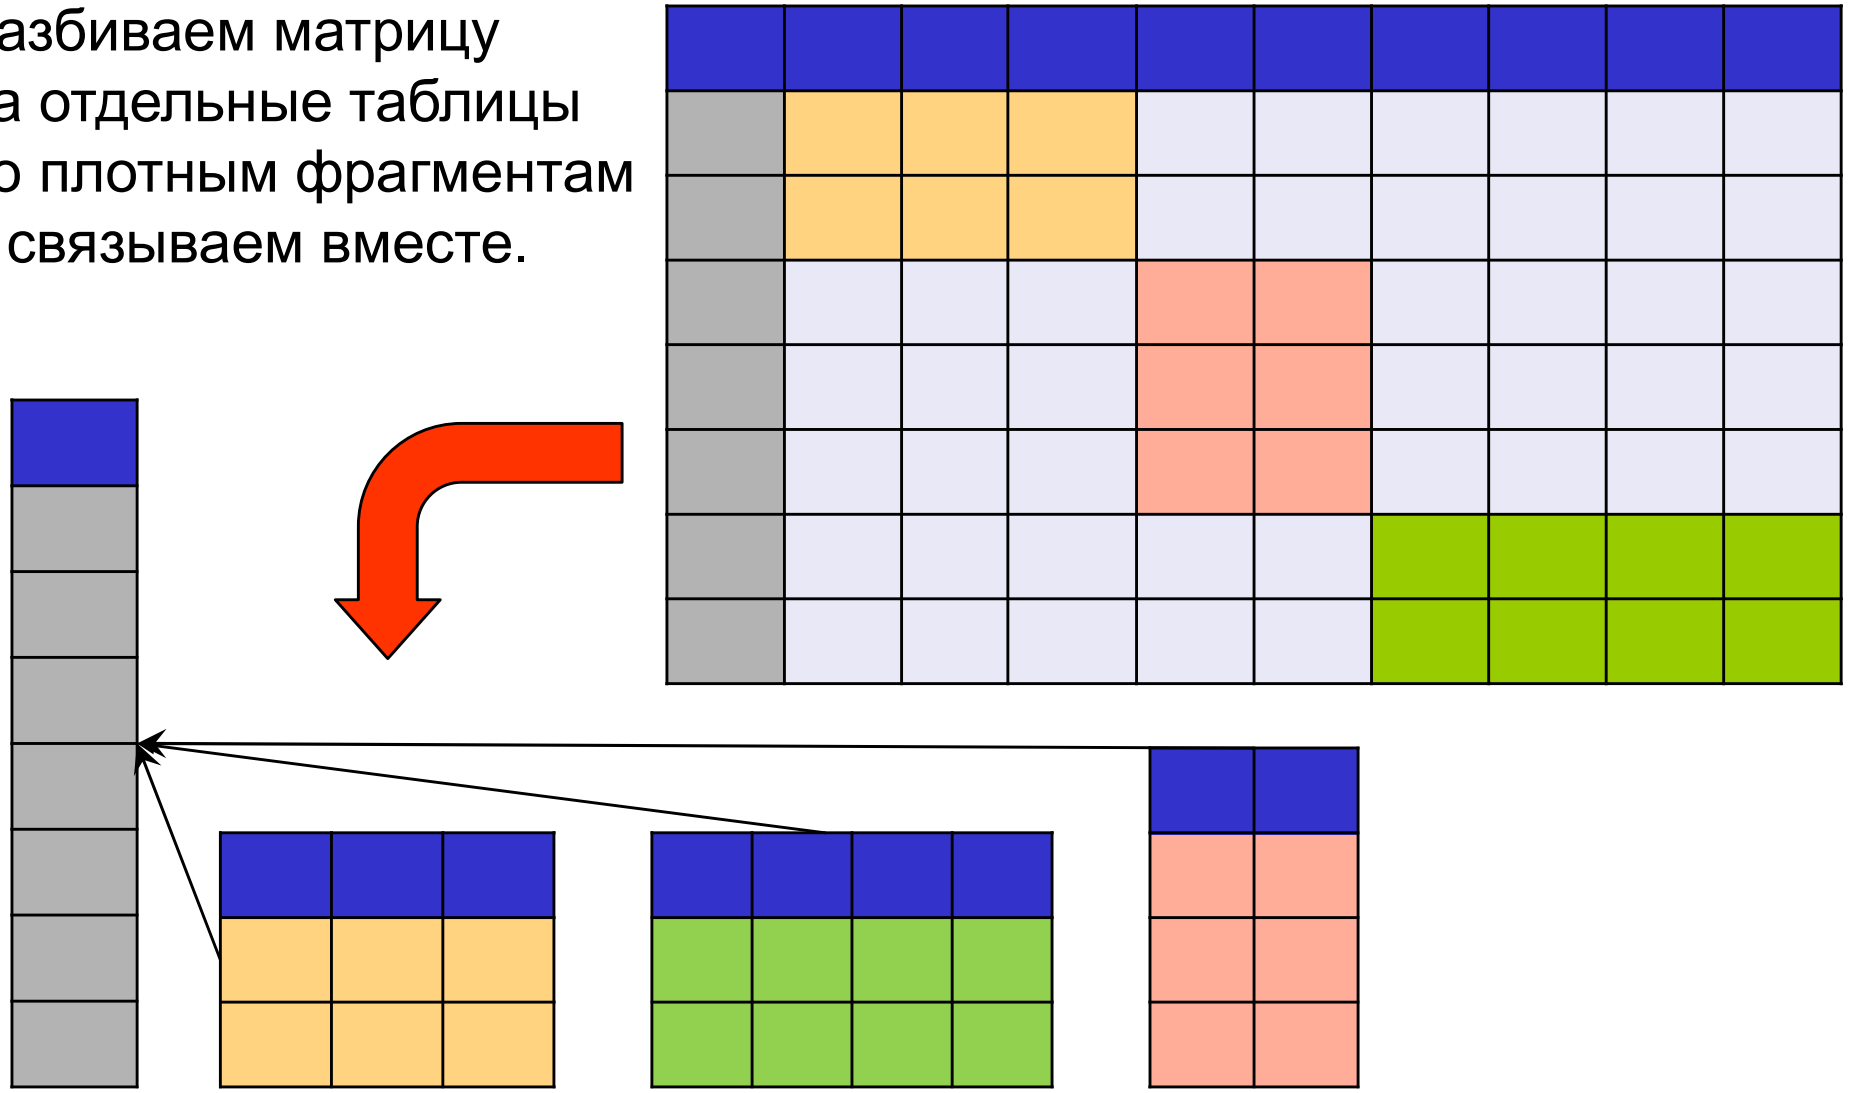
Неопределённый состав сущностей предметной области

- Пример 7. Учёт объектов городского хозяйства
- Пример 8. Прототипирование БД (?)

Разреженная таблица с плотными фрагментами

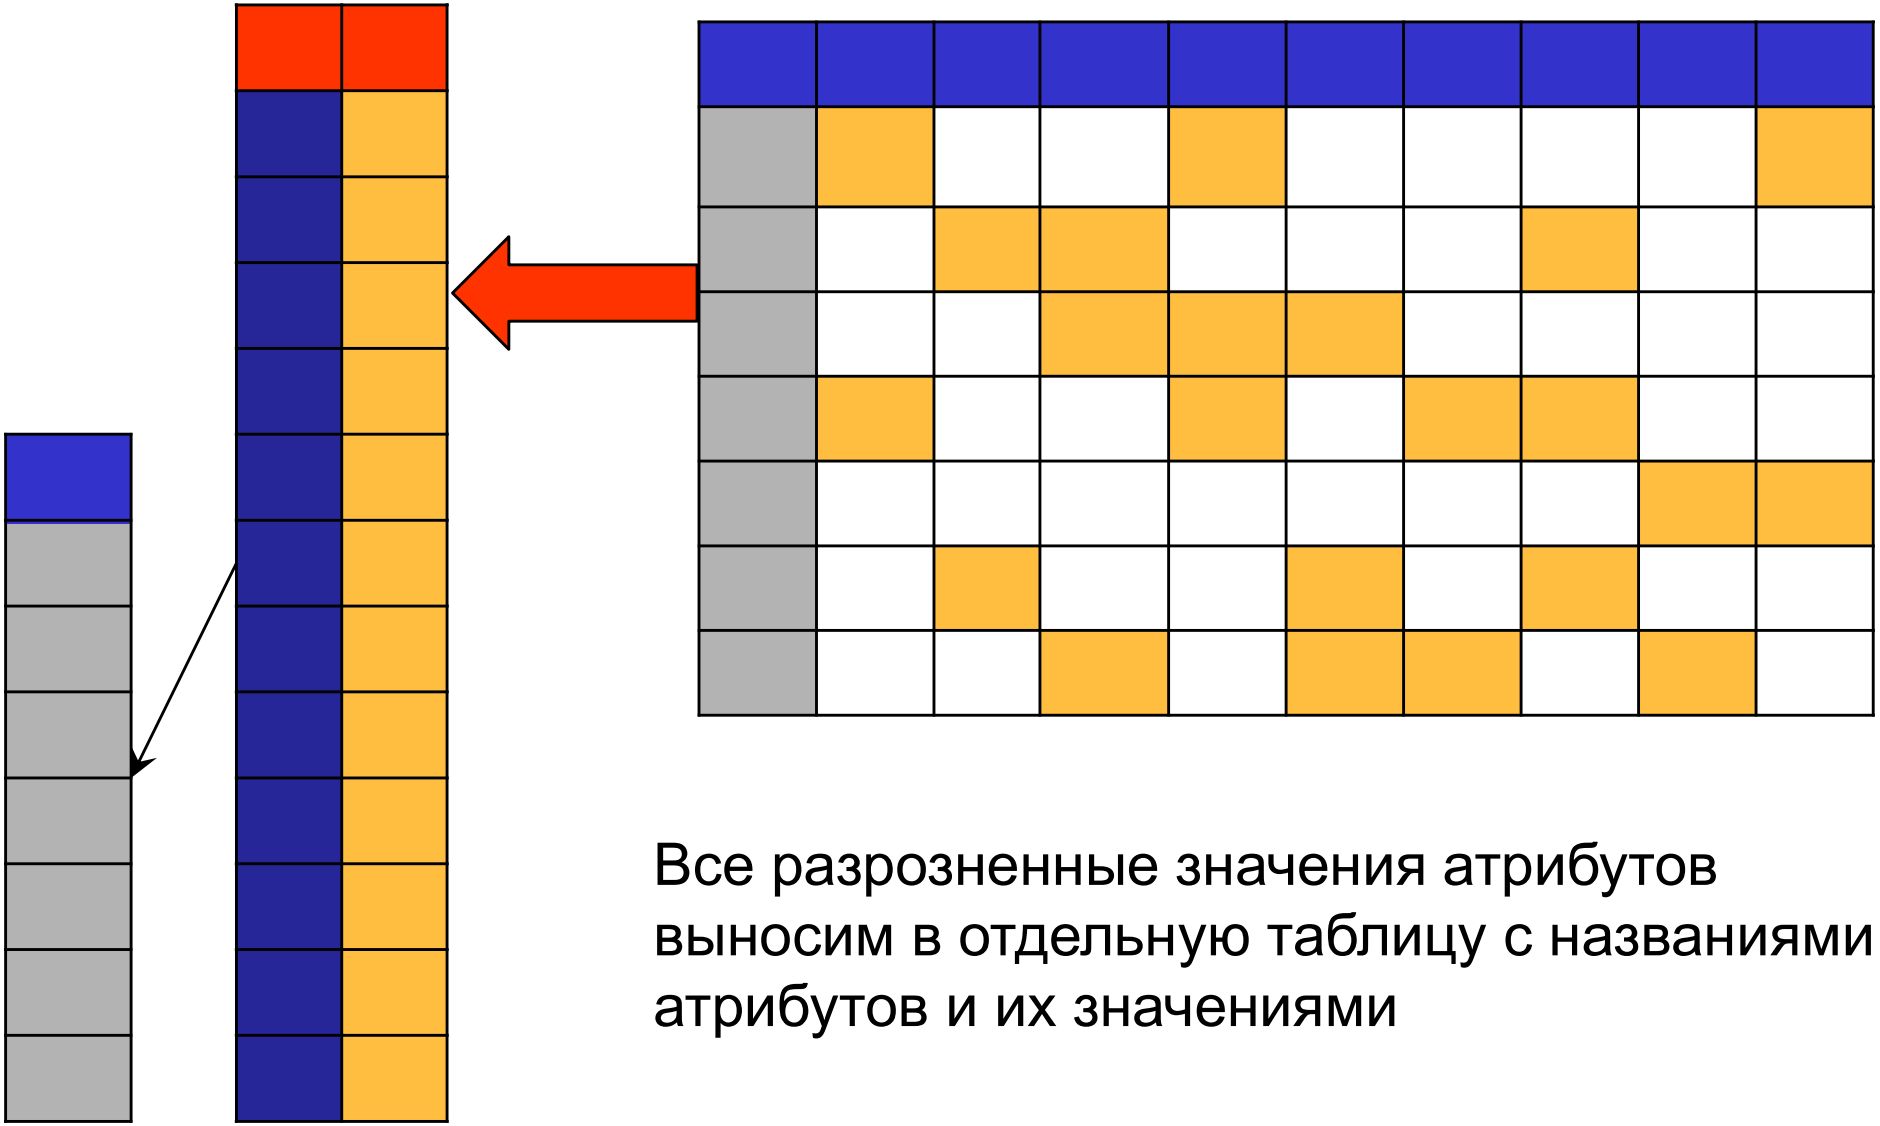
EAV

Разбиваем матрицу
на отдельные таблицы
по плотным фрагментам
и связываем вместе.



Разреженная таблица с неплотными фрагментами

EAV



Все разрозненные значения атрибутов выносим в отдельную таблицу с названиями атрибутов и их значениями

Идея метамоделирования таблицы

EAV

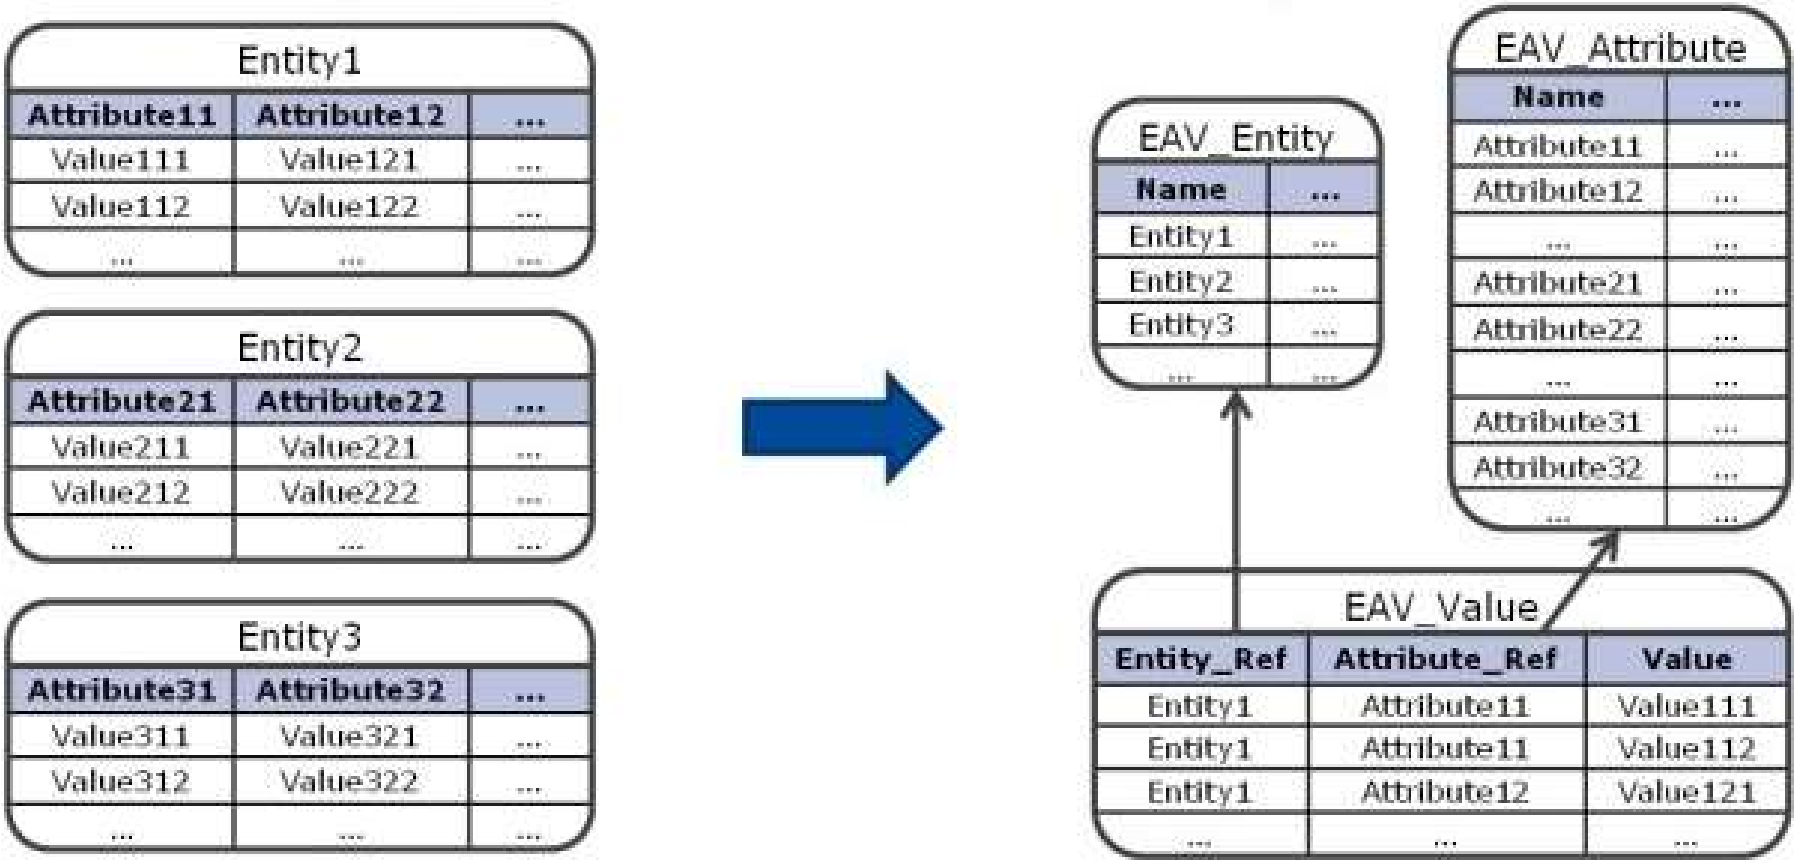
Широкая (горизонтальная) таблица «Простыня»

№	Имя	Фамилия	Пол	Дата рожд	Отрасль
1	Marinna	Kauschke	Female	1973-03-15	Financial Services
2	Olia	O' Mullan	Female	1973-03-24	Health
3	Brigitte	Whellams	Female	1973-05-09	n/a
4	Ivy	Farr	Female	1973-07-03	IT
5	Beverlee	Ungerechts	Female	1973-10-03	Manufacturing
6	Skipp	Swales	Male	1973-11-14	Entertainment
7	Leighton	Firbanks	Male	1973-12-22	Retail
8	Claudetta	Ricciardiello	Female	1974-04-30	Financial Services
9	Harland	Messenger	Male	1974-05-28	Retail

Узкая (вертикальная) таблица «Портянка»

№	Имя атрибута	Значение
1	Имя	Marinna
1	Фамилия	Kauschke
1	Пол	Female
1	Дата рожд	1973-03-15
1	Отрасль	Financial Services
2	Имя	Olia
2	Фамилия	O' Mullan
2	Пол	Female
2	Дата рожд	1973-03-24
2	Отрасль	Health
3	Имя	Brigitte
3	Фамилия	Whellams
3	Пол	Female
3	Дата рожд	1973-05-09
4	Имя	Ivy
4	Фамилия	Farr
4	Пол	Female
4	Дата рожд	1973-07-03
4	Отрасль	IT
...	...	...

Объединение нескольких сущностей в модели EAV

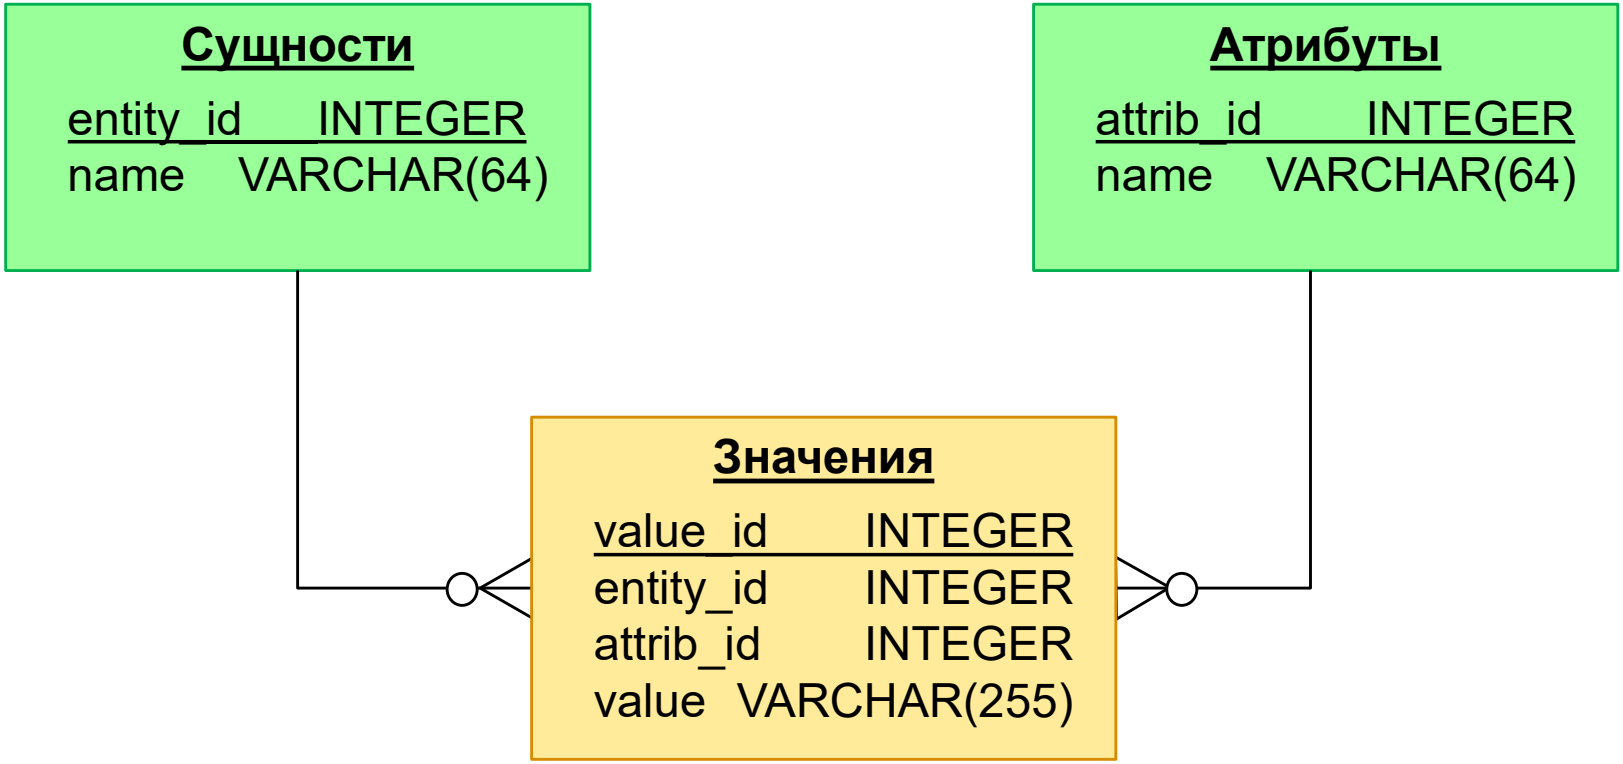


Варианты реализации модели EAV

1. Типовая реализация с 3-мя таблицами
2. Простая реализация с 2-мя таблицами
3. Реализация с разделением значений по типам
4. Реализация с отражением экземпляров сущностей
5. Гибридная реализация с выделением фиксированных и переменных атрибутов

Типовая реализация модели EAV

Денормализованная модель данных с 3-мя таблицами.
В кросс-таблице **Значения** заведены ссылки на справочники **Атрибуты** и **Сущности**, а также значение атрибута.
Т.е. имеем атрибут с наложенными значениями строкового типа.

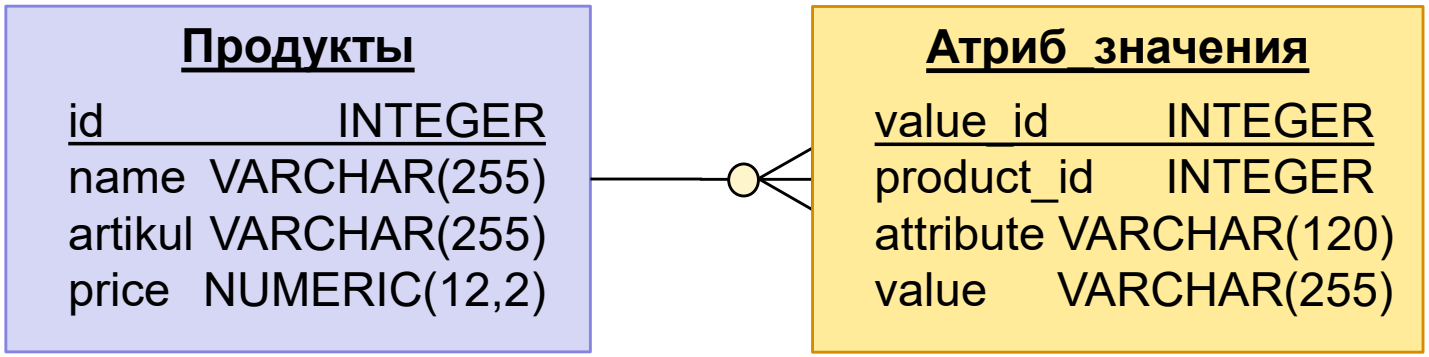


Простая реализация модели

EAV

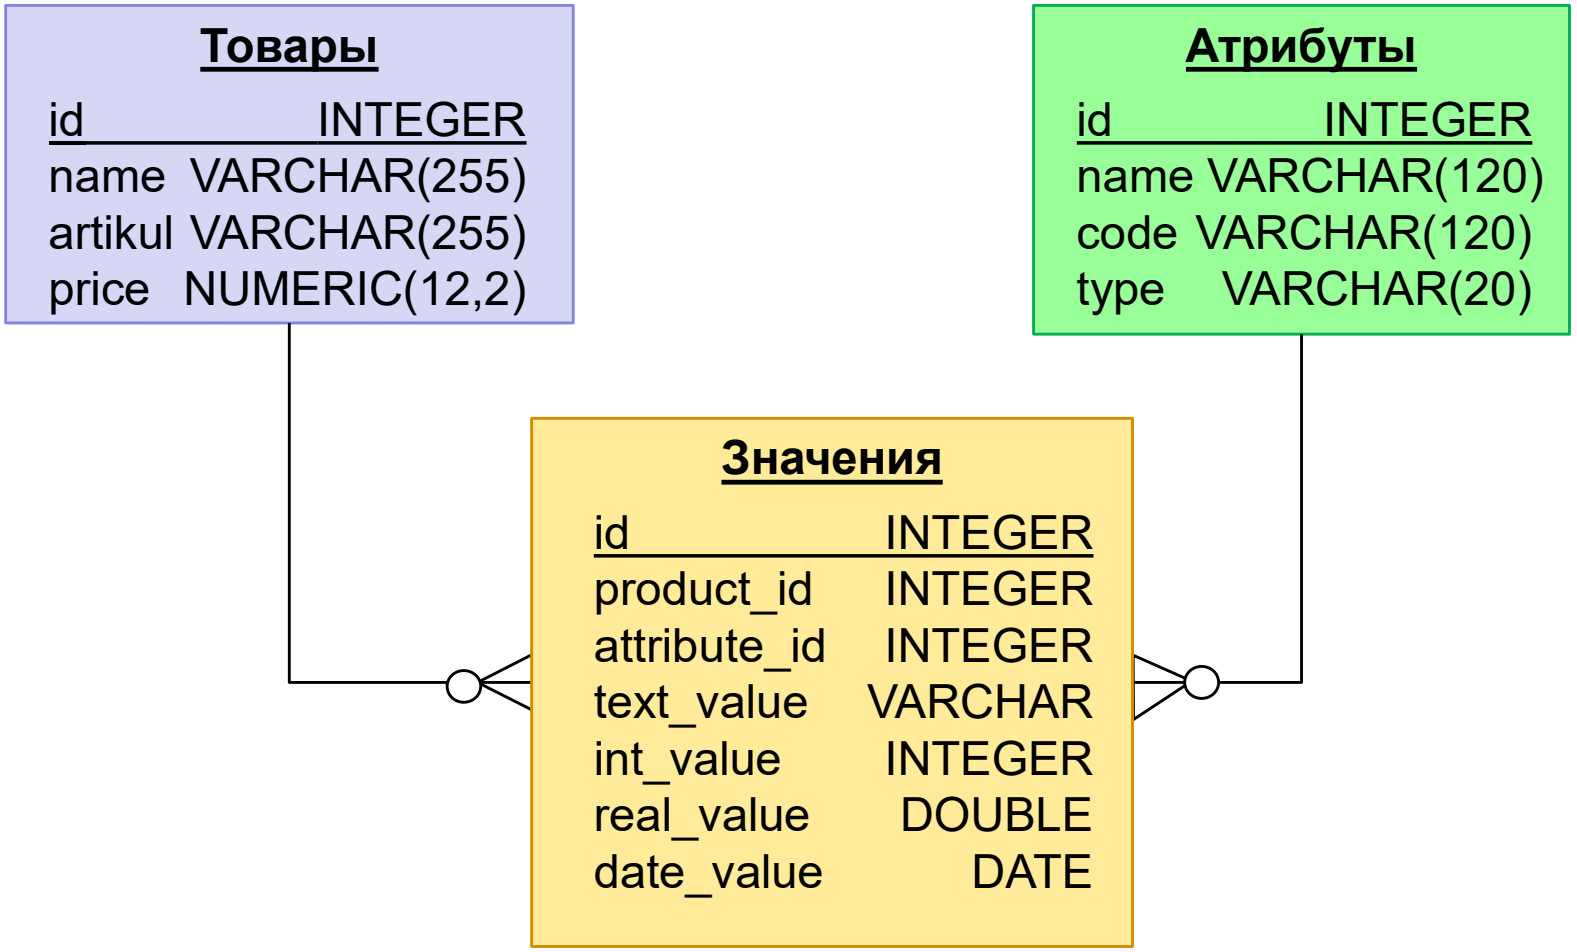
Пример каталога товаров

Денормализованная модель с 2-мя таблицами.
В таблице **Атрибут-значение** приведены имена атрибутов,
их значения и ссылка на справочник **Продуктов**.
Атрибуты всех типов данных представлены в виде строки текста.



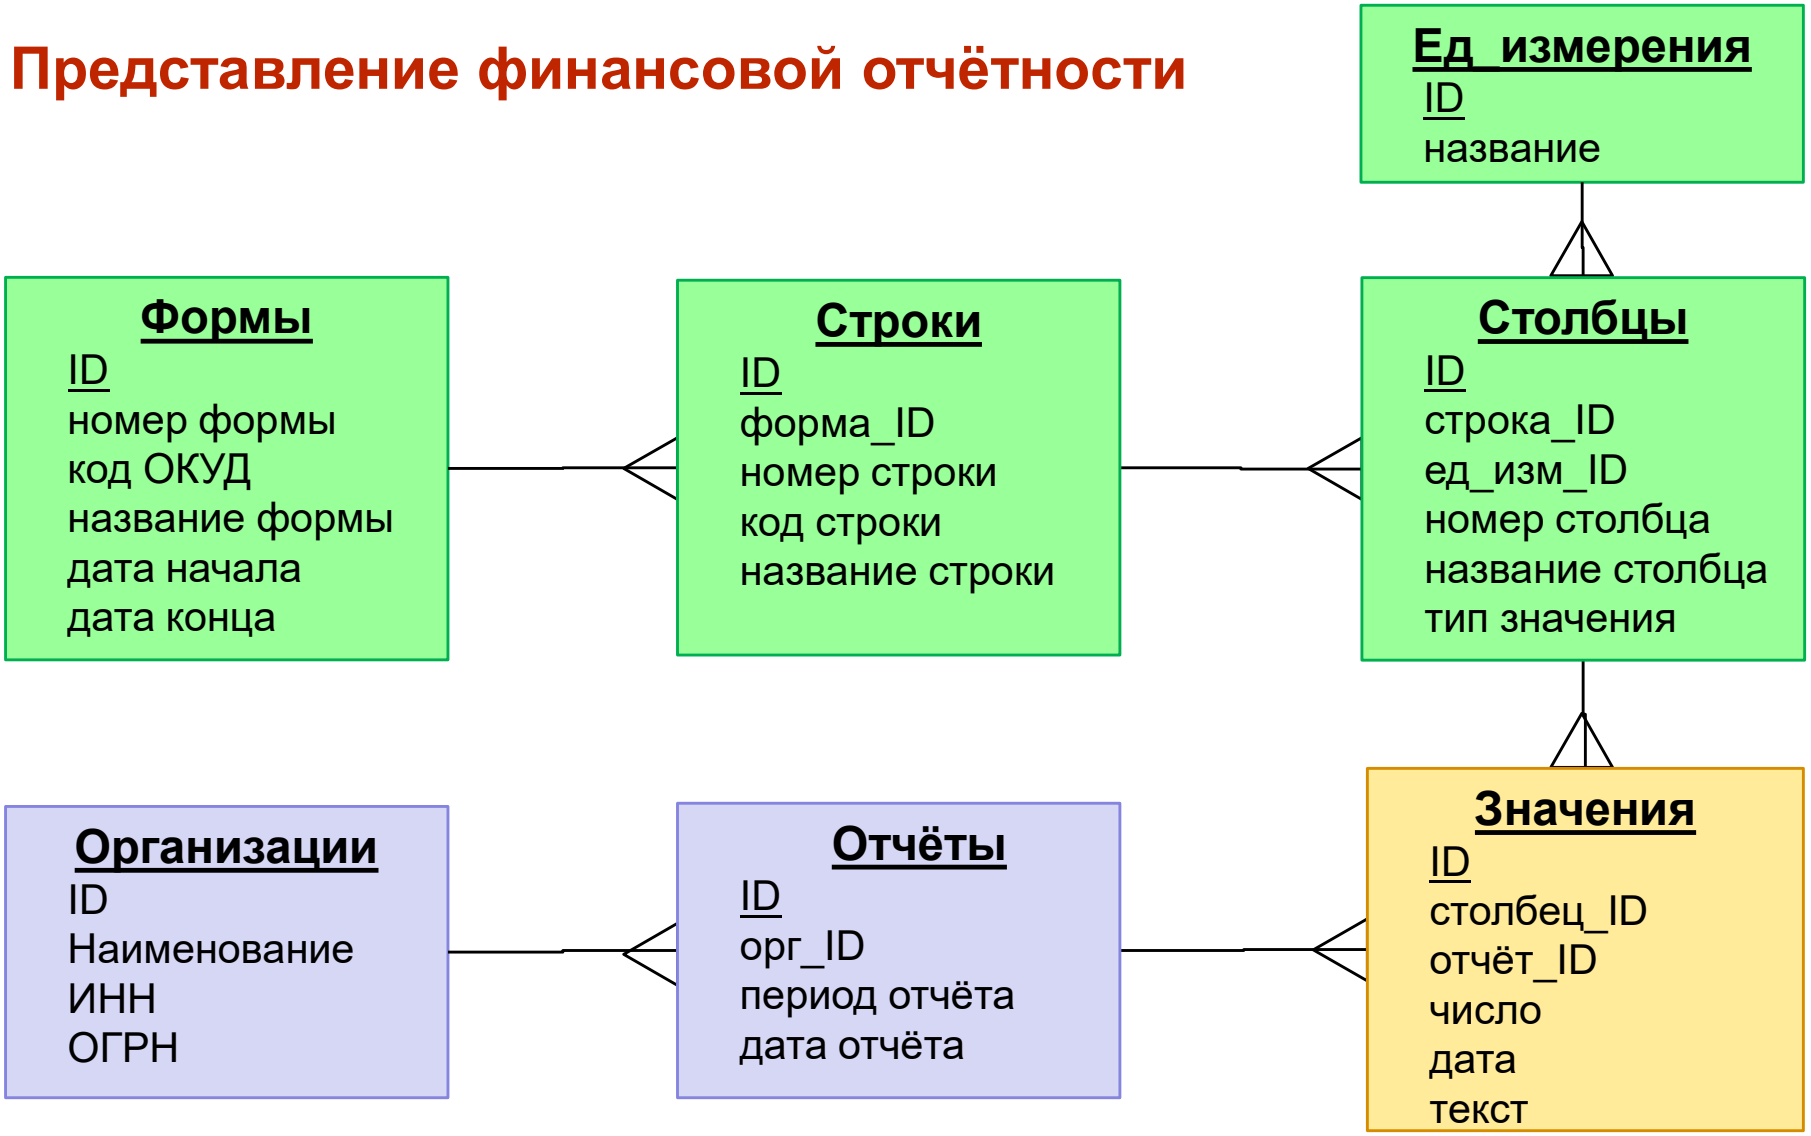
Реализация модели EAV с разделением значений по типам

Пример каталога с широкой номенклатурой товаров



Гибридная реализация модели EAV

Представление финансовой отчётности



Достоинства и недостатки модели EAV

Абстрактное представление сущности с неограниченным наборов атрибутов для задания простых или составных значений различных типов данных.

Гибкость добавления новых понятий: не требуется изменение состава и структуры таблиц БД.

Автоматизированное создание и изменение атрибутов: возможно на любом этапе жизненного цикла системы.

Генерация форм ввода данных по описанию атрибутов.

Нельзя использовать ограничения целостности СУБД, надо ввод данных контролировать в клиентской программе.

Сложность обработки данных из-за трудности индексации и невозможности использовать имеющиеся справочники.

Падение производительности на порядок из-за усложнения запросов, чтения сотен тысяч записей, отсутствия оптимизации для такой модели данных и возможной конвертации данных.

Альтернативы EAV

Встроенные в БД сложные типы данных:

- XML
- JSON / JSONB

NOSQL базы данных типа key-value:

- Redis
- Memcached
- Riak
- Apache Cassandra

NOSQL базы данных типа column-family based:

- Apache Cassandra
- Apache HBase

Пример атрибута типа XML

Описания участников создания книги:

Books
(PK) book_ID SMALLINT
…
creators XML
…

Пример значения атрибута:

‘**<creators editor=**“Петров А.В.”
authors=“Шкатов П.Н. Черненький В.М.”
artist=“Хомич И.С.”
/>’

Пример атрибута типа JSON

Описания участников создания книги:

Books
(PK) book_ID SMALLINT
…
creators JSON
…

Пример значения атрибута:

'{"редактор": "Петров А.В.",
"авторы": ["Иванов С.П.", "Семёнов В.К."],
"художник": "Филин Р.Б."}'

Какие знания по модели EAV проверяются в РК2?

1. Модель «сущность – атрибут – значение» EAV
2. Сценарии применения УМД
3. Идея метамоделирования разреженных таблиц
4. Объединение нескольких сущностей в модель EAV
5. Пример реализации модели EAV
6. Модель EAV с разделением значений по типам
7. Достоинства и недостатки модели EAV
8. Альтернативы EAV, примеры XML/JSON

Терпения и удачи всем, кто связан с моделированием данных

Спасибо за внимание!



Валерий Иванович Артемьев

МГТУ имени Н.Э. Баумана,

кафедра ИУ-5

Банк России,
Департамент данных, проектов и процессов

Тел.: +7(495) 753-96-25
e-mail: viart@bmstu.ru