Модели данных

B5. Якорные модели данных Anchor



Московский государственный технический университет
имени Н.Э. Баумана

Факультет ИБМ

Ноя 2024 года

Москва

Артемьев Валерий Иванович © 2024

Data Vault и Anchor Modeling



https://learndatavault.com/

Dan Linstedt



http://www.anchormodeling.com/

Lars Rönnbäck

Обе методологии:

- Повышают градус нормализации выше 3НФ
- Вводят свои типы таблиц и накладывают жесткие ограничение на их использование
- При использовании создают несколько тысяч таблиц

Взамен обещают:

- Уменьшить постоянное дублирования данных в SCD2 от изменения всего одного атрибута
- Избавить от деструктивных изменений, только расширение модели (даже при изменении кардинальности связи, боль классического ХД)
- Позволить дорабатывать хранилище легко и быстро (мистика)

Что такое якорная модель данных?



Гибкий метод моделирования для работы с постоянно растущими объемами данных, меняющимися со временем по структуре или содержанию.
Сочетает преимущества высокой степени нормализации и интуитивной понятности.

Имеется графическая нотация для моделирования, аналогичная ER-моделированию, *с расширениями для работы с временными данными*. *С помощью формализованных правил* модели переводят в БД.

Похожа на модель Data Vault, но более строгая. Таблицы в БД будут в основном в 6NF.

Основания якорной модели данных

6NF *Таблица в этой форме тогда и только тогда, когда она вообще не удовлетворяет никаким нетривиальным зависимостям соединения*.

- C. J. Date, Darwen, and Lorentzos
  Temporal Data and the Relational Model
- Esteban Zimányi
  Temporal Universal Quantification

EER *Расширенная модель "сущность – связь" основана на генерализации и специализации.*

- Peter P. Chen
  Towards a Unified View of Data
- Richard Barker
  CASE Method: Entity Relationship Modelling

AM *Якорная модель*

- Olle Regardt
  Первое применение в 2002 г.
- Lars Rönnbäck
  Формализация подхода 2007-2008 годы

Сценарии применения Anchor



Хранилища данных (Data Warehouse)

- реляционные базы данных SQL
- массивно-параллельные БД NewSQL

Аналитические хранилища данных

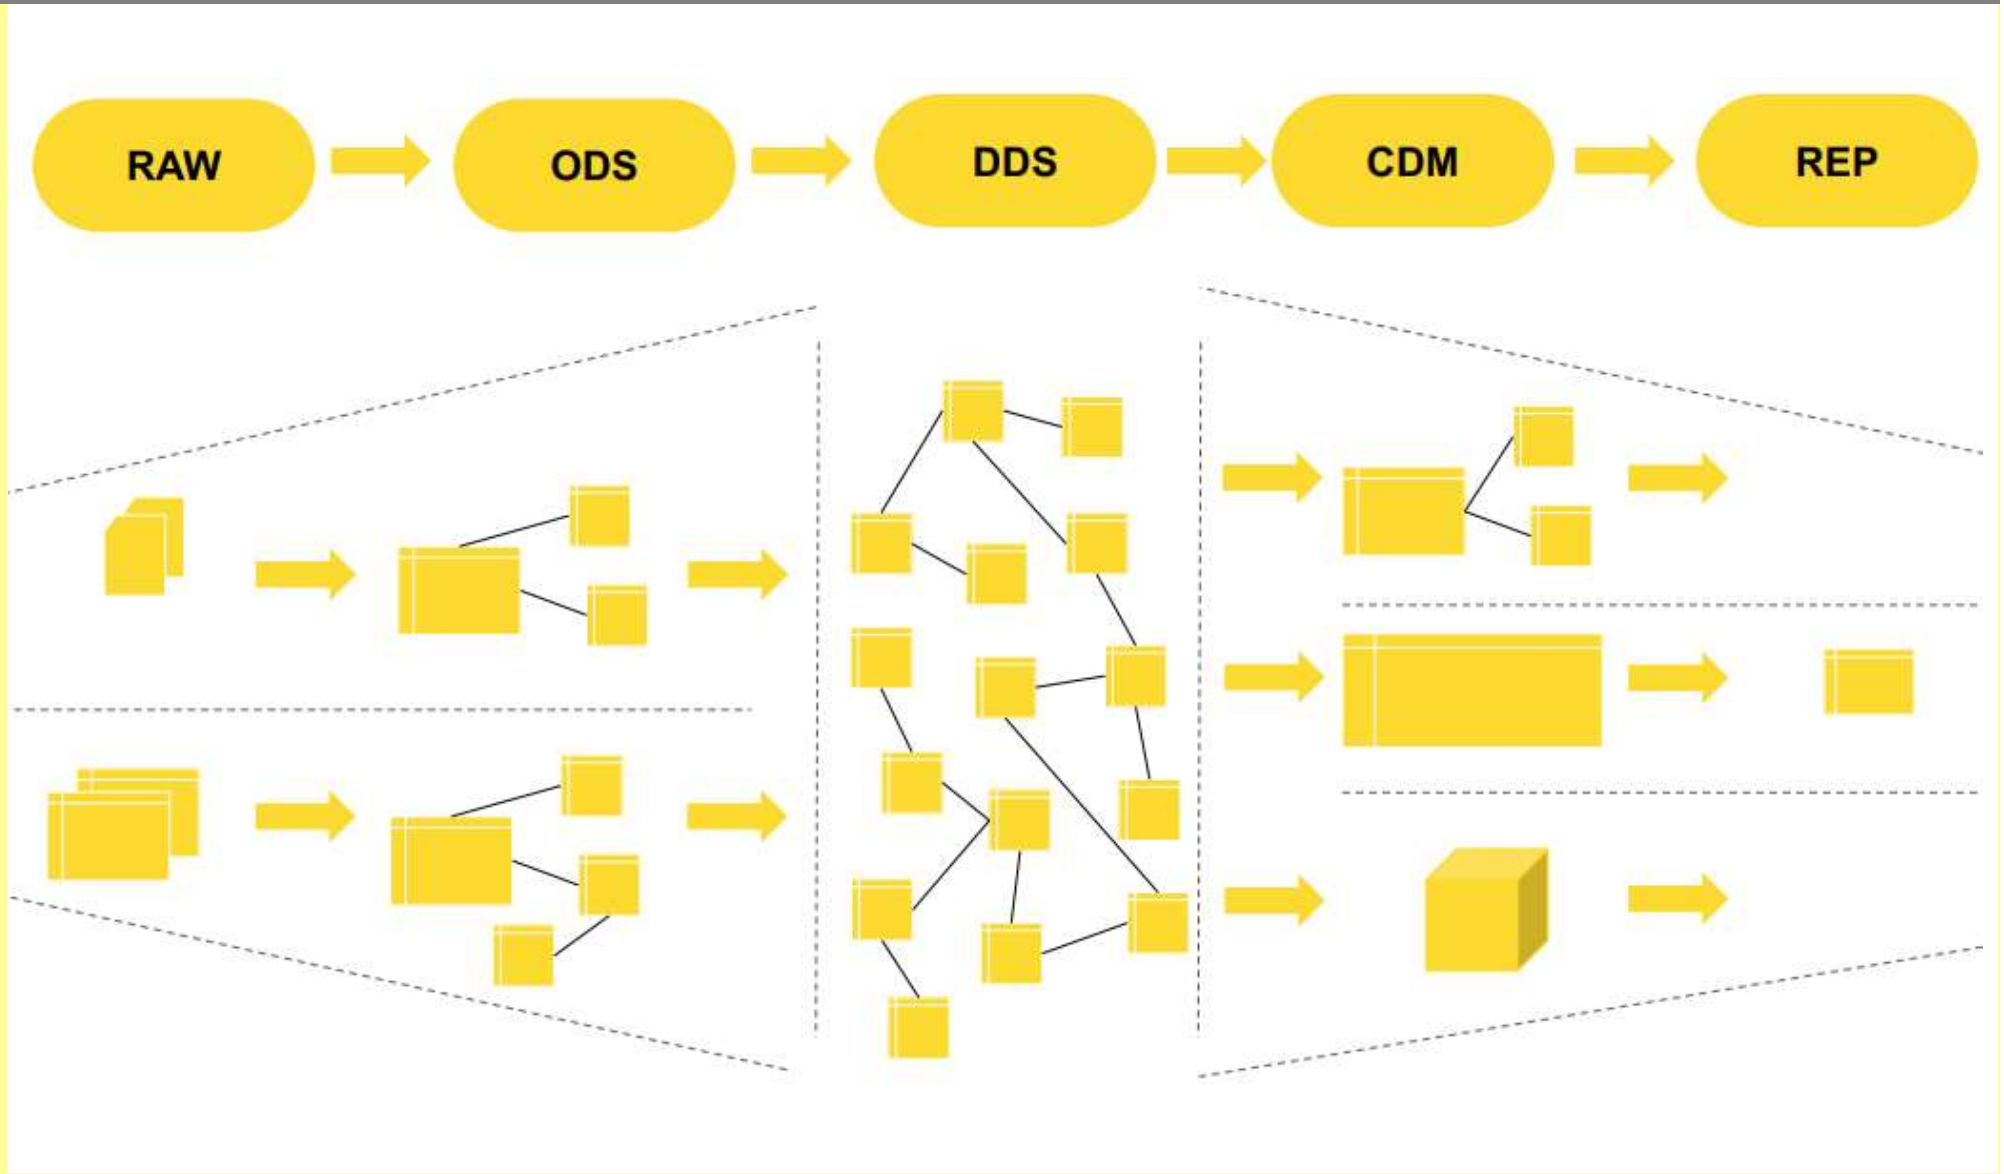
- озёра данных (Date Lake)
  на основе NoSQL в среде Big Data
- Концептуальное моделирование данных

Страховые агентства

Логистические компании

Интернет-магазины

Архитектура ХД – требуются разные модели данных



Основные элементы якорной модели Anchor



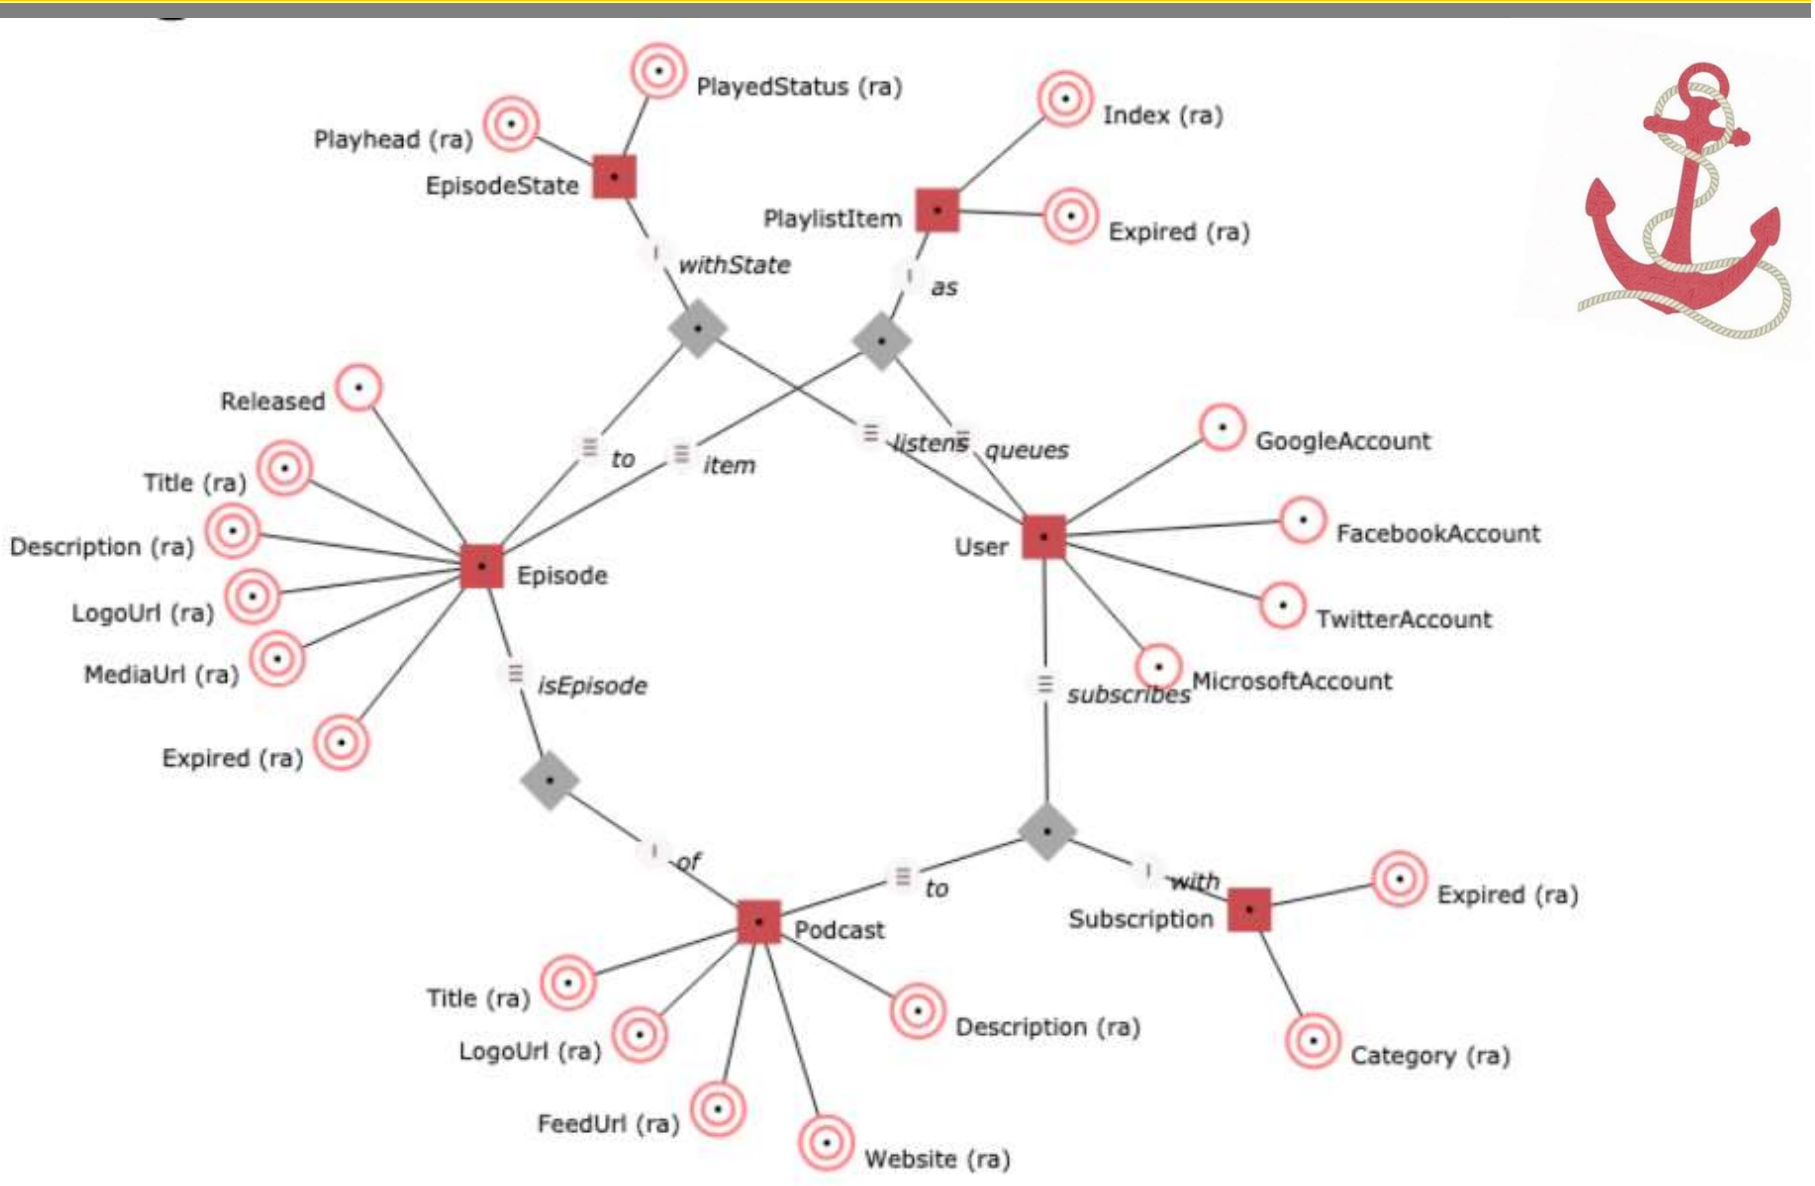
Простота конструкции и гибкость схемы данных за счёт минимума реляционных таблиц:

1. **Якорь (Anchor)** – *идентификатор* бизнес-сущности
2. **Привязка (Tie)** – поддержка *многосторонних и многосвязных отношений* бизнес-сущностей
3. **Атрибут (Attribute)** – *одно свойство* бизнес-сущности, представленное *в ретроспективе* (факт или метрика или описание).
4. **Узел (Knote)** – *представление общих свойств*, например, состояния.

Якоря, Привязки и Узлы образуют стабильный «скелет» модели данных, Атрибуты добавляют необходимую «плоть».

Используется специальная графическая нотация якорной модели, близкая к нотации П. Чена.

Диаграмма якорной модели данных



Элемент Якорь (Anchor) – идентификатор бизнес-сущности

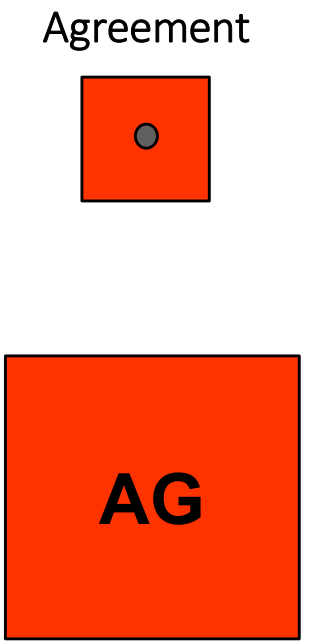
Таблица, хранящая основное представление бизнес-сущности предметной области с функциональной позиции (Клиент, Продукт, Заказ, Событие и пр.)



Содержит следующие поля:

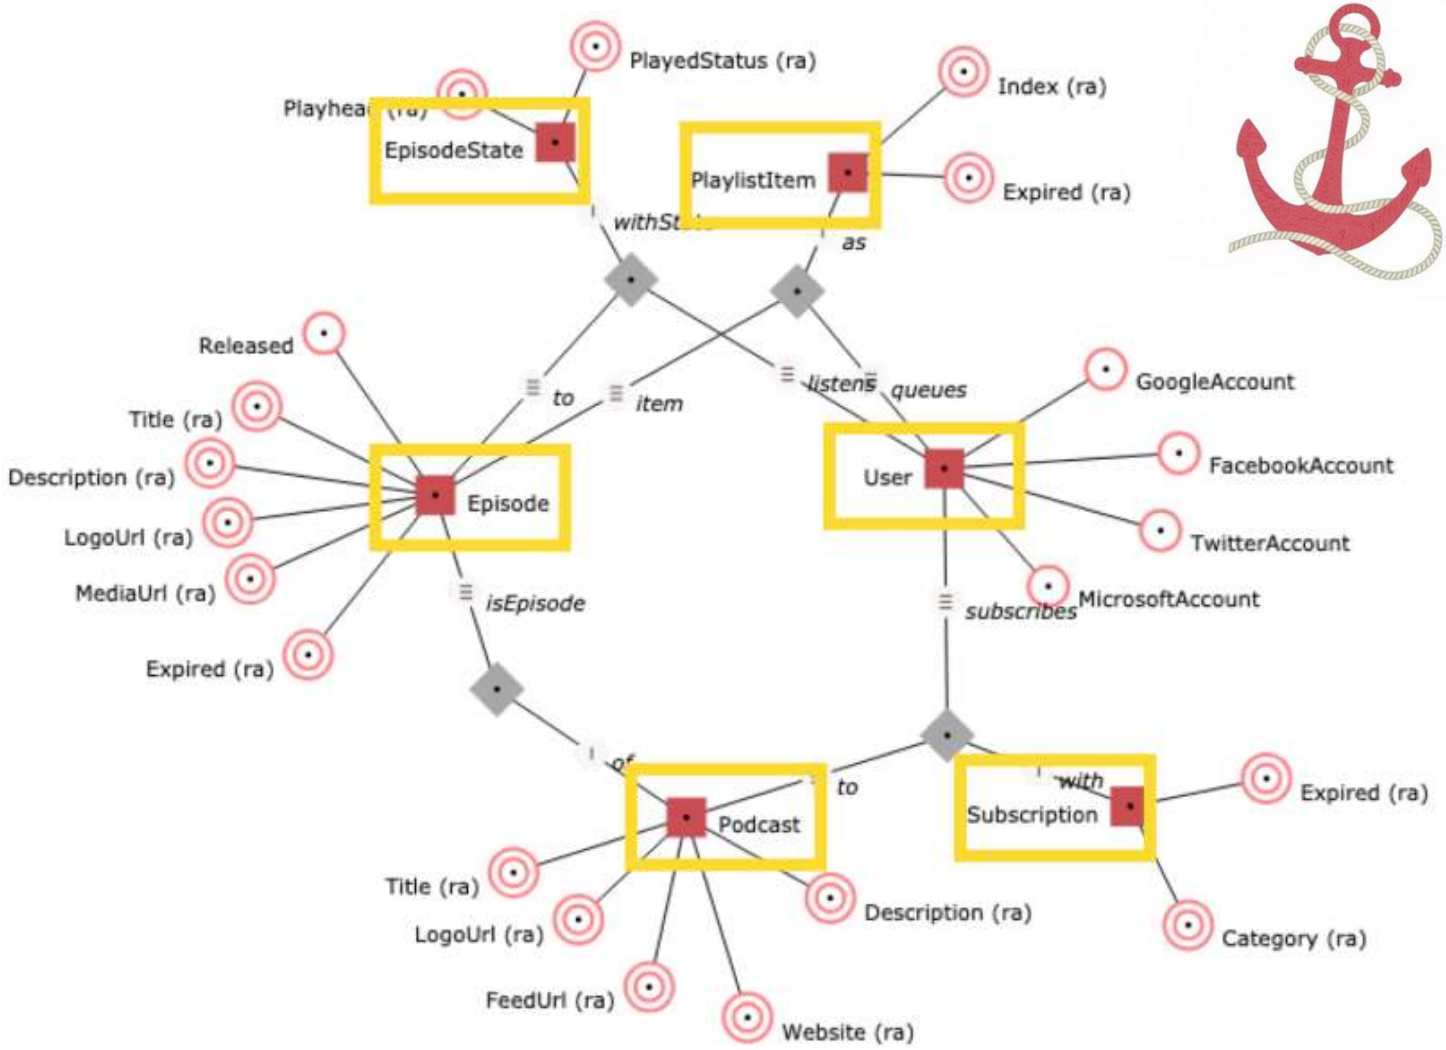
- *уникальный и неизменный суррогатный ключ*, идентифицирующий сущность.
- *операционные метаданные*:
  - время первоначальной загрузки сущности в хранилище (load timestamp)
  - источник данных (record source) – название системы, БД или файла, откуда были взяты данные.

На диаграмме изображается как красный квадрат. Аналогична таблице Хаб в модели Data Vault, но *без бизнес-ключей*.



Миграция суррогатных ключей в Якори модели данных Anchor





Элемент Связь (Tie) – представление связей между бизнес-сущностями

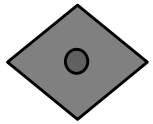
Таблица, объединяющая несколько бизнес-сущностей связью «многие-ко-многим».



Содержит следующие поля:

- *внешние ключи* связываемых сущностей
- *первичный ключ – составной ключ* из внешних ключей связываемых сущностей
- *поддержка истории* (from date)
- *операционные метаданные* (когда, где, как):
  - дата и время загрузки данных (load timestamp)
  - источник данных для записи (record source).

Agreement_Part



Адаптирует отношение «много ко многим» и решает проблемы с масштабируемостью и гибкостью.

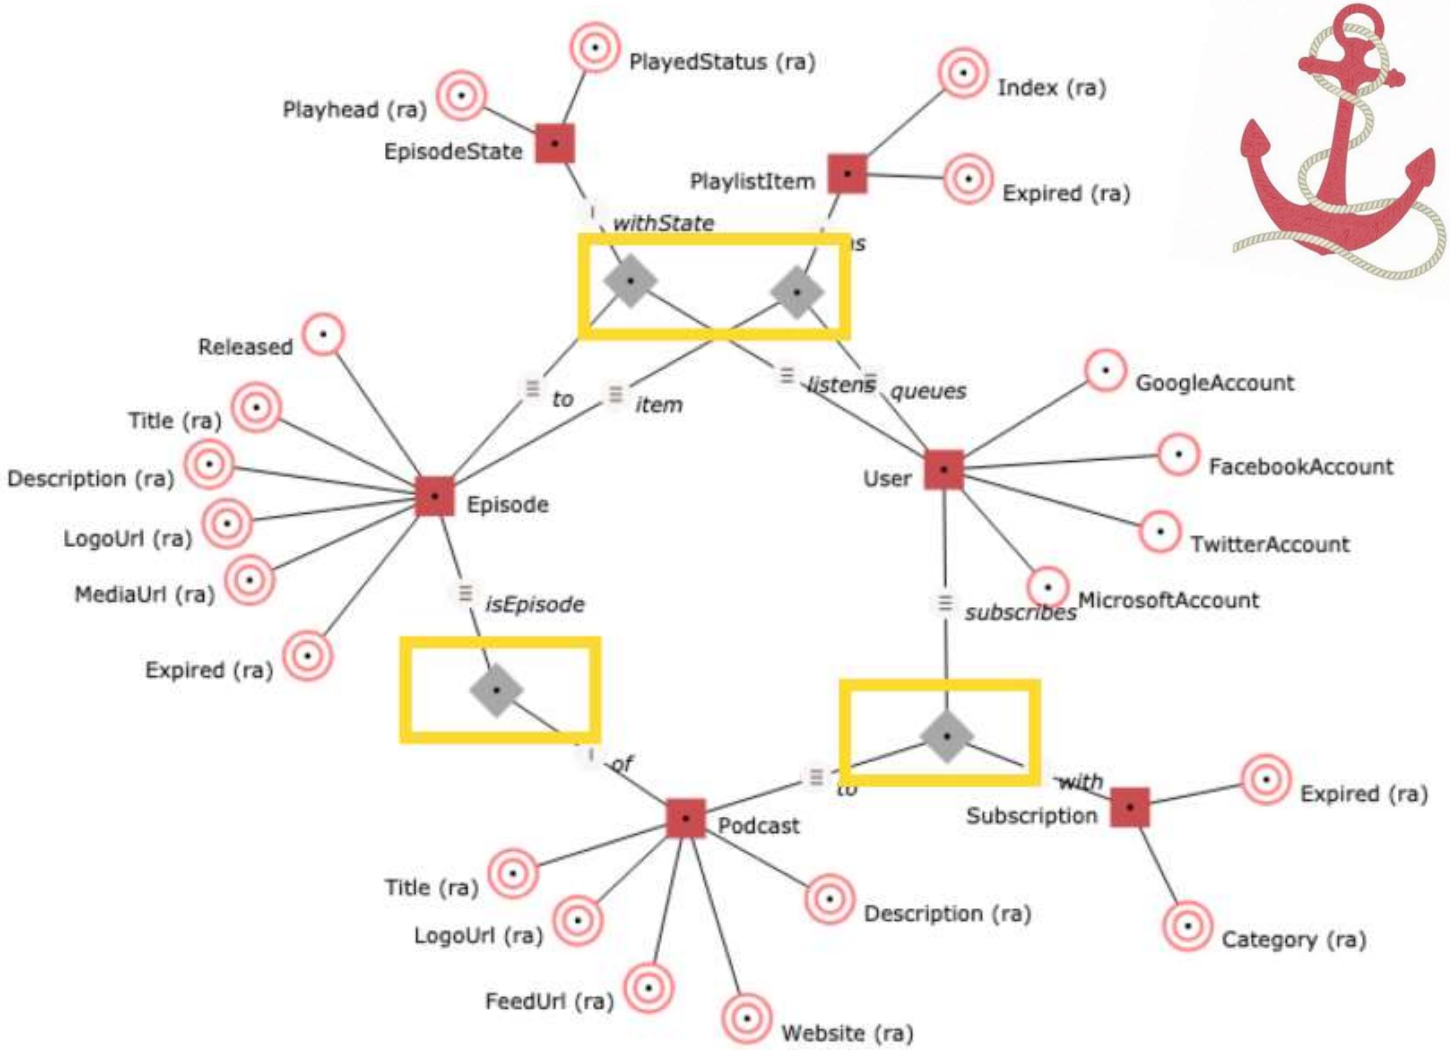


Не допустимы ссылки между Связями.

У Связи нет бизнес-атрибутов.

Миграция внешних ключей в Связи якорной модели данных





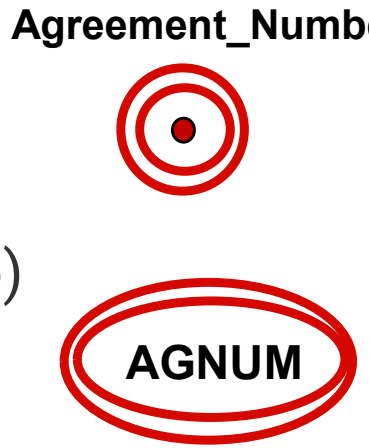
Элемент Атрибут (Attribute) – атрибут бизнес-сущности

Таблица, хранящая одно значение свойства бизнес-сущности.



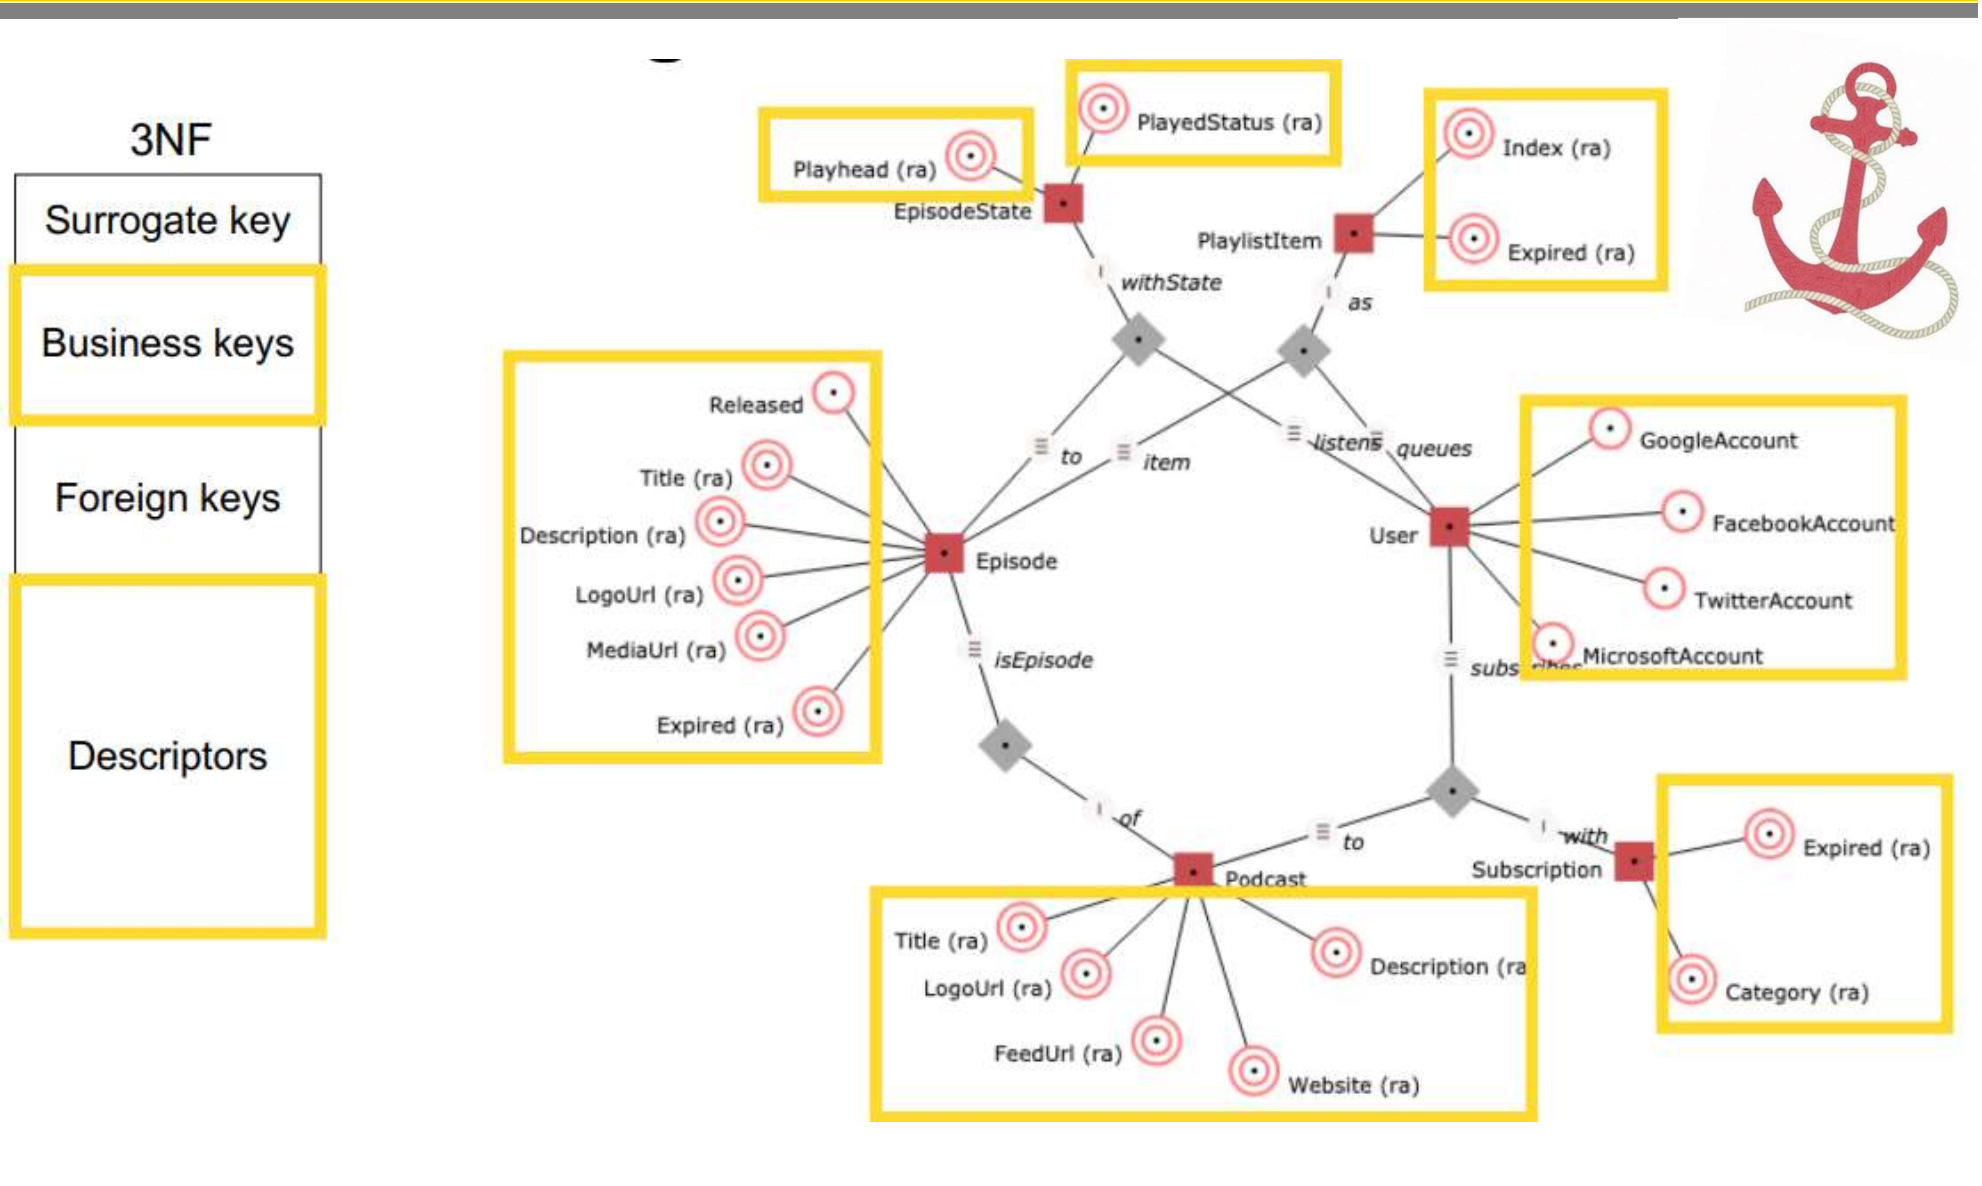
Содержит следующие поля:

- *внешний ключ якоря, к которому относится атрибут*
- *значение атрибута*
- *поддержка истории (from date)*
- *операционные метаданные* (когда, где, как):
  - дата и время загрузки данных (load timestamp)
  - источник данных для записи (record source).



На диаграмме двойной контур по атрибуту или привязке указывает, что сохраняется история изменений.

Миграция бизнес-ключей и атрибутов в якорную модель данных



Элемент Узел (Knote) – представление общих свойств

Таблица, хранящая одно значение общих свойств, например простой справочник.

Содержит следующие поля:

- *суррогатный ключ узла*
- *тип узла*
- *операционные метаданные* (когда, где, как)

Узел – это, по сути, свернутая привязка.
Может никогда не изменяться со временем.
Часто используется для ”ввода” отношения или атрибута. Может использоваться для значений домена или таблиц состояний (например, для отметки «удалено»).
Нет Узлов в стандартной ER-нотации. Однако квадратная форма указывает на то, что это нечто среднее между привязкой и атрибутом.

Поддержка историчности данных



- **Стратегия нулевого обновления ZeUS**
  только операции вставить/выбрать
  при нормальной работе
  удалять только для устранения ошибок
- **Последовательности**
  только FromDate и никогда ToDate
  Якори вечны в базе данных.

FromDate указывает на последнюю версию,
т.е. *текущую версию данных*.

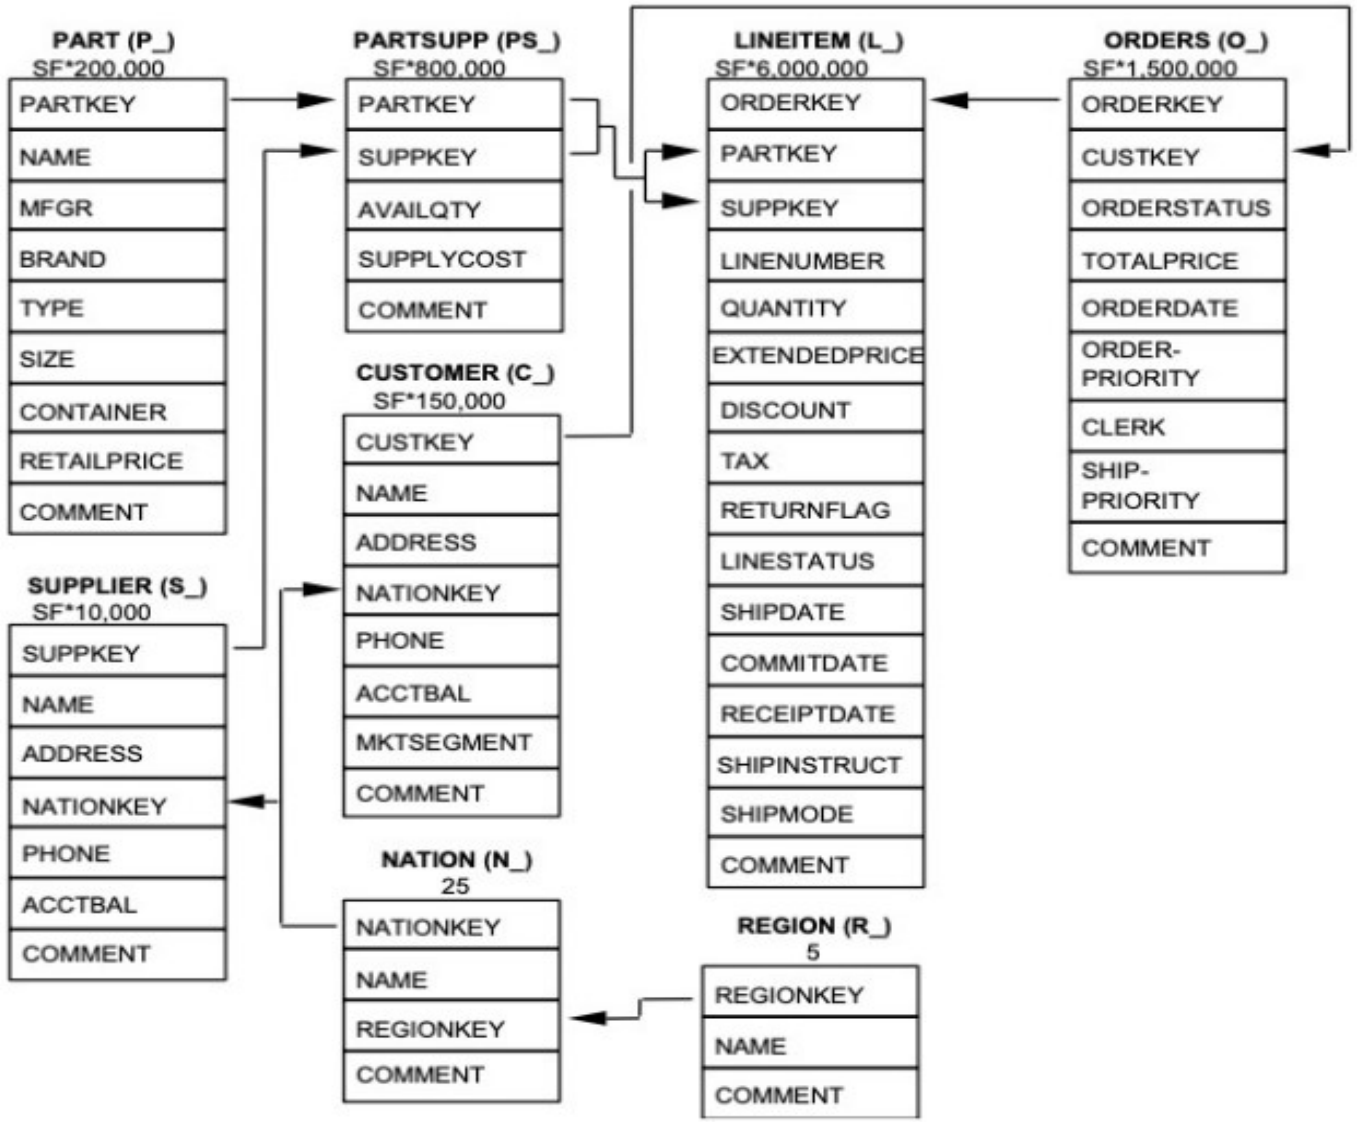
Вечность якорей означает, что *всё может меняться,*
но не идентичность.

Соглашения об именовании



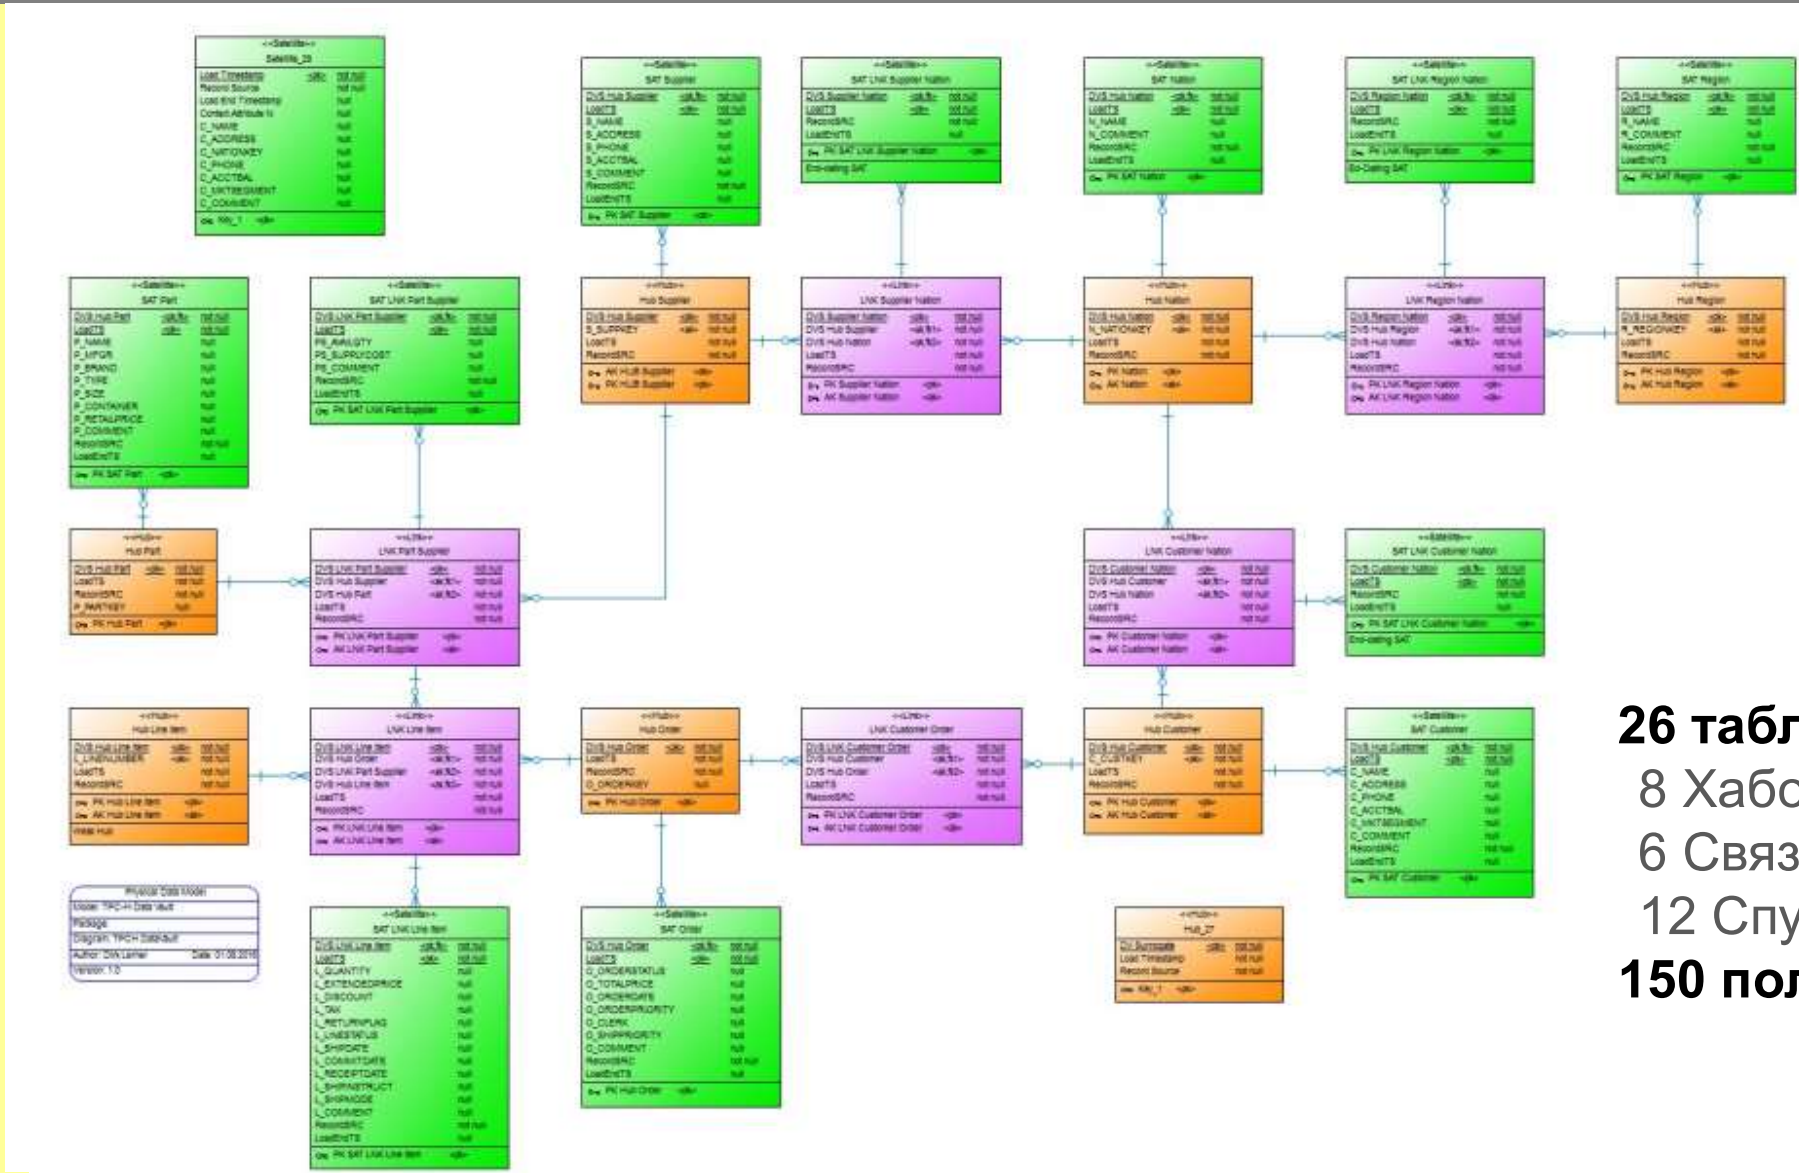
- Якорь имеет префикс из 2-х заглавных букв
  - AG_Agreement
- Атрибуты имеют префикс из пяти букв
  - AGNUM_AgreementNumber
  - первые 2 буквы взяты из якоря
- Связи имеют префикс из четырех (или 2n) букв
  - AGPA_Agreement_Part
  - буквы взяты из соседних якорей
- Узлы имеют префикс из 3-х букв
- Позволяет избежать плохих моделей
  - потому что возникнут проблемы с именованием

Модель данных 3NF для теста производительности TPC-H



8 таблиц
9 ссылок
62 поля

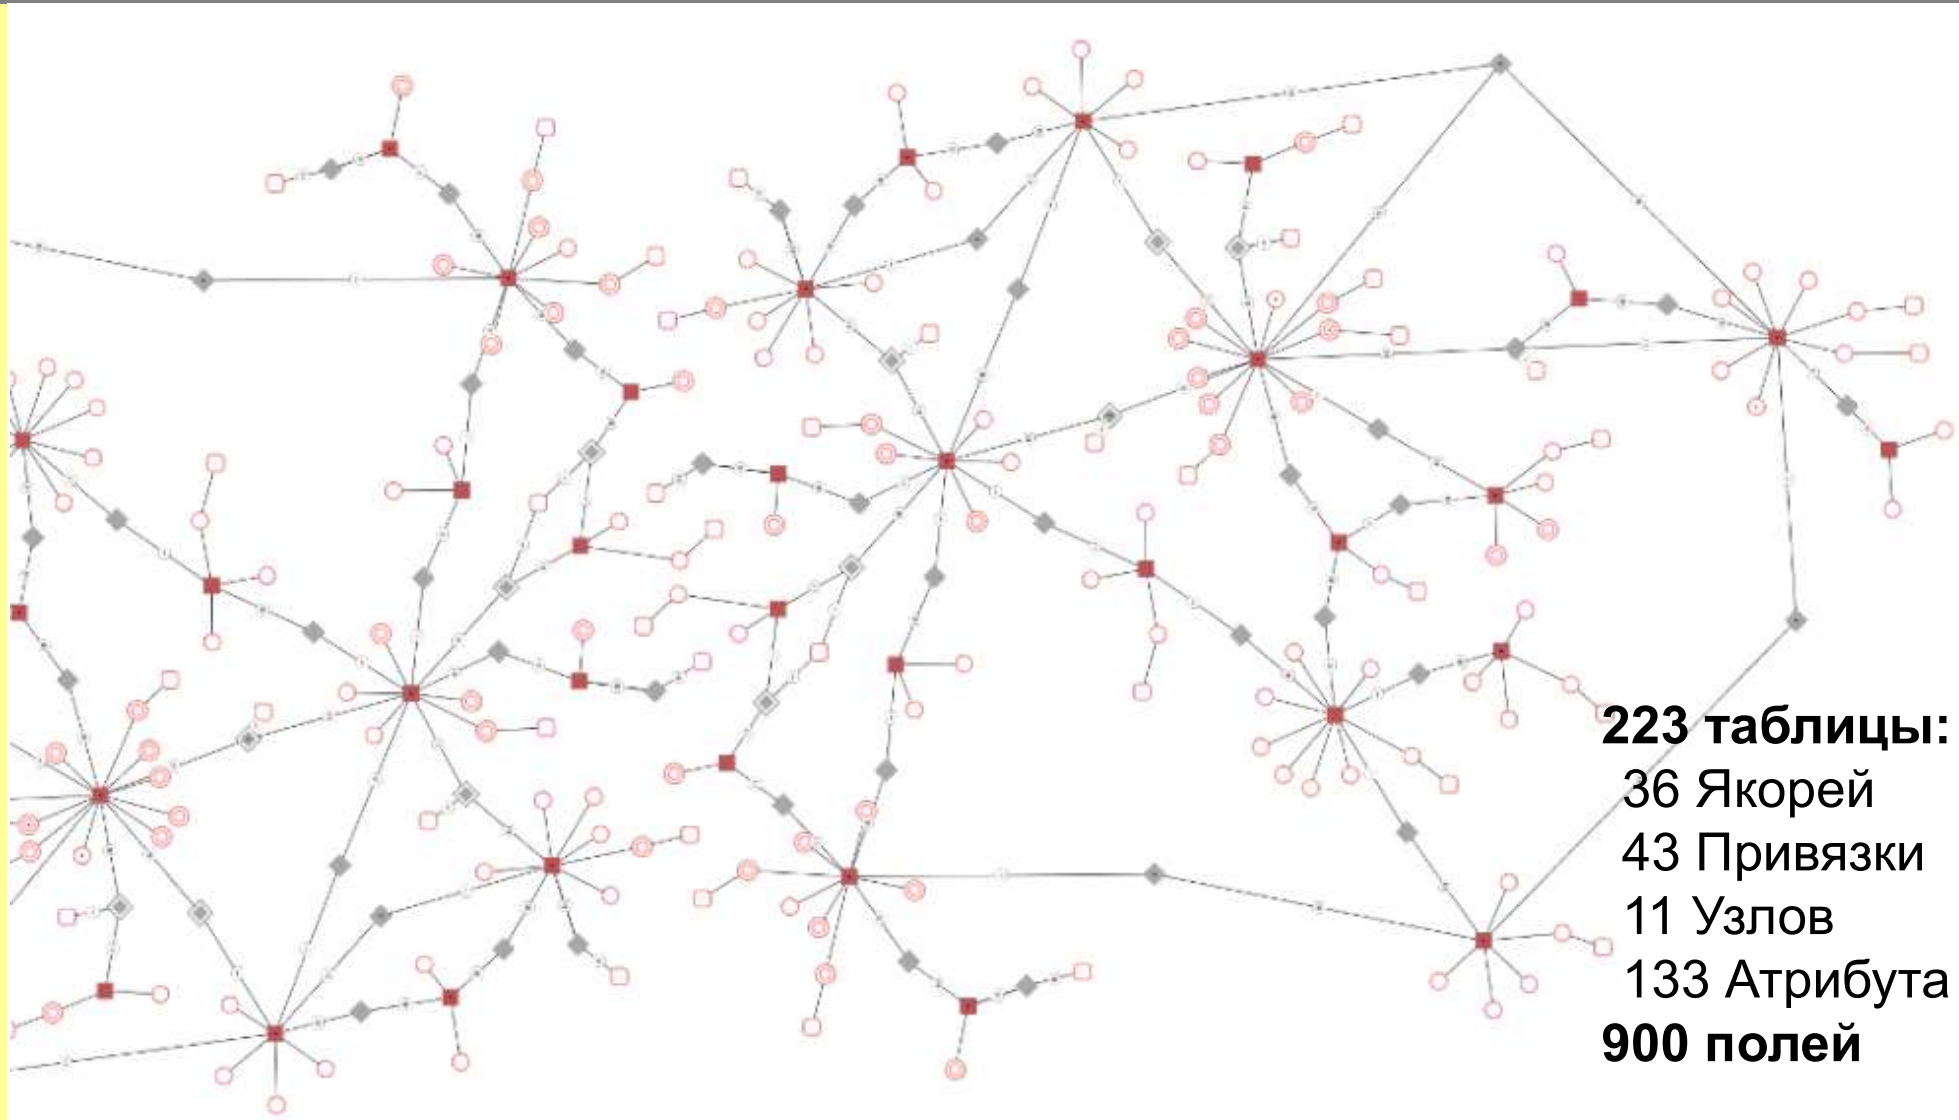
Модель Data Vault для теста производительности TPC-H



26 таблиц:
- 8 Хабов
- 6 Связей
- 12 Спутников

150 полей

Модель данных Anchor для теста производительности TPC-H (фрагмент)



223 таблицы:
36 Якорей
43 Привязки
11 Узлов
133 Атрибута
900 полей

Достоинства якорной модели такие же, как и у модели Data Vault



Простота моделирования – используется минимум элементов

Строгая система правил для описания взаимоотношений между элементами

Отсутствие избыточности данных – атрибуты используются только для хранения изменений.

Расширяемость модели – по мере необходимости можно изменить структуру КХД, добавить и сопоставить данные из новых источников.

Максимальное распараллеливание загрузки данных в хранилище за счёт максимальной независимости элементов.

Поддержка Agile-принципов – новые данные подключаются к существующей модели без модификации её структуры.

Поддерживает разделение обязанностей – Федеративное ХД, контроль доступа, прототипирование

Достоинства только якорной модели



Историзация по замыслу

– медленно меняющиеся измерения
– поддержка истории для отношений и атрибутов
– поддержка всех типов историзации
– легко включить историзацию.

Уменьшение (или исключение) дублирования значений одних атрибутов при изменении других

– выигрыш практически прямо пропорционален среднему количеству версий на объект измерения

Устраняет NULL

– этим обеспечивает ссылочную целостность
– кардинальность 0 или 1.

Обрабатывает «сирот» – быстро поступающие факты

– либо знаем достаточно из записи , чтобы создать привязку
– либо можем исключить связь, не добавляя никаких строк в таблицу отношений до появления информации.

Недостатки якорной модели



Снижение производительности из-за большого числа операций соединения данных из разных таблиц.

Сложности с настройкой проверки данных из-за большого количества сущностей со сложными связями.

Большое количество таблиц и соединений, повышающих риск ошибок.

Потребность в высококвалифицированных архитекторах (разработчиках) до сих пор актуальна**.**

Необходимость постоянной поддержки и документирования - специалистам необходимы дополнительные знания для понимания документации.

Усложнение актуализации документации.

Повышение стоимости разработки, так как увеличивается порог входа в проект и количество задач для обслуживания.

Невозможность сохранить исправленные данные, так как якорное моделирование не допускает обновления данных.

Сравнение подходов к проектированию

сложно эксплуатировать, просто вносить изменений

Никакого	Звезда и снежинка	Data Vault	Anchor modeling
› Денормализация до 1НФ	› Нормализация до 3НФ	› Строгая нормализация	› Ультра строгая нормализация
› Можно использовать без подготовки	› Можно использовать с минимальной подготовкой	› Нельзя использовать без подготовки	› Нельзя использовать без подготовки
› Неустойчиво к изменениям	› Неудобно перестраивать	› Не надо перестраивать (с ограничениями)	› Не надо перестраивать
› Дублирование информации	› Минимальное дублирование информации	› Минимальное дублирование информации	› Нет дублирования информации
› Нет join	› Приемлемое количество join	› Большое количество join	› Ультра количество join

легко эксплуатировать, сложно вносить изменения

Высоко нормализованная гибридная модель hNhM

Ключевая идея:

выбирать оптимальный формат хранения для каждого конкретного случая.

Требования:

- Разделение логического и физического моделирования
- Возможность эмулировать как Data Vault, так и Anchor Modeling,
- Высокая нормализация (вплоть до предельной 6НФ)
- Параллельная загрузка из разных источников
- Повторяемость результата при повторной загрузке
- Устойчивость к изменению в бизнесе, модульность и масштабируемость
- Удобство использования при построении витрин.

Основные тренды моделирования данных в 2024 году



1. Широкое распространение *отраслевых моделей*
2. Рост и влияние *Концептуального моделирования*
3. Рост популярности *графов знаний*
4. Улучшение возможностей *самообслуживания*
5. *Моделирование «на лету»*
6. *Совместное моделирование*

Основные тренды моделирования данных в 2026 году

Семантическое моделирование становится обязательным. LLM нужно понимать не только структуру, но и смысл данных. В архитектуру встраивают онтологии, таксономии, бизнес-глоссарии, сети сущностей и контекстные метаданные.

Мультимодальные данные – графы знаний объединяют в единую машиночитаемую сеть структурированные, неструктурированные и потоковые данные.

Моделирование данных для реального времени и событийных потоков. Требуются новые подходы, чтобы моделировать схемы для обработки потоков, обогащения данных в реальном времени, хранения транзакционных событий и интеграции с микросервисами.

Доминирование облачных решений и Lakehouse – моделирование данных оптимизируют под облачные платформы и под архитектуру Lakehouse (гибкость озёр данных и управляемость ХД).

Демократизация и подход «данные как продукт». Кроме ИТ, бизнес активно участвуют в моделировании данных в режиме самообслуживания. Данные проектируют как продукты с чётким владельцем, документацией, измеримой ценностью и жизненным циклом.

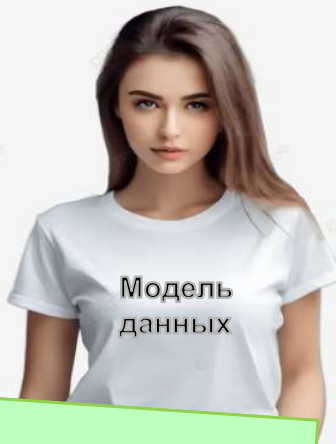
Интеграция ИИ и автоматизация – генеративный ИИ и LLM берут на себя рутину: помогают оптимизировать схемы БД, автоматически генерировать и поддерживать ETL, заполнять пропуски, проводить очистку.

Синтетические данные. Для устранения дефицита качественных данных в медицине или финансах применяют генерацию синтетических данных с помощью ИИ, создавая реалистичные выборки для обучения моделей или тестирования без раскрытия конфиденциальной информации.

Распределённые архитектуры Data Mesh. Крупные предприятия уходят от жёсткой централизации к распределённым моделям по доменным продуктам для повышения масштабируемости и гибкости, но требуется согласование семантики между доменами и единый стандарт управления.

Спасибо за внимание!

Терпения и удачи всем, кто связан с моделями данных



Валерий Иванович Артемьев

МГТУ имени Н.Э. Баумана, кафедра ИУ-5

Банк России
Департамент данных, проектов и процессов

Тел.: +7(495) 753-96-25
e-mail: viart@bmstu.ru